

I-CLIC

Intelegent Clinic Care

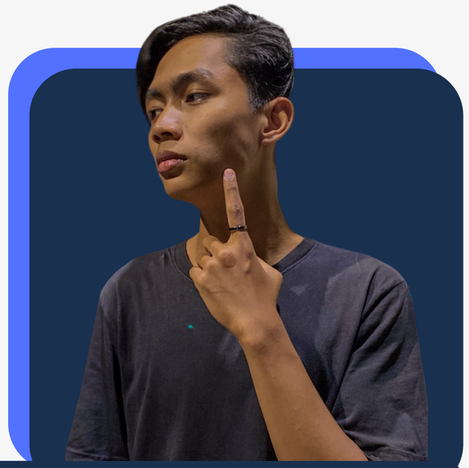
Project Base Learning

INTRODUCTION I-CLIC TEAM



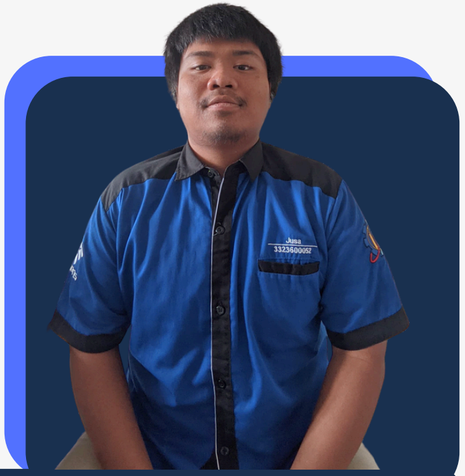
DIMAS FIRMANSYAH (3323600034)

MODELING & BACKEND SYSTEM



AFIF HANIFUDDIN (3323600050)

LLM & CHATBOT CONSULTATION SYSTEM



ADRIYANS JUSA HUTAPEA (3323600052)

FRONT END & USER LOGIN SYSTEM

OVERVIEW

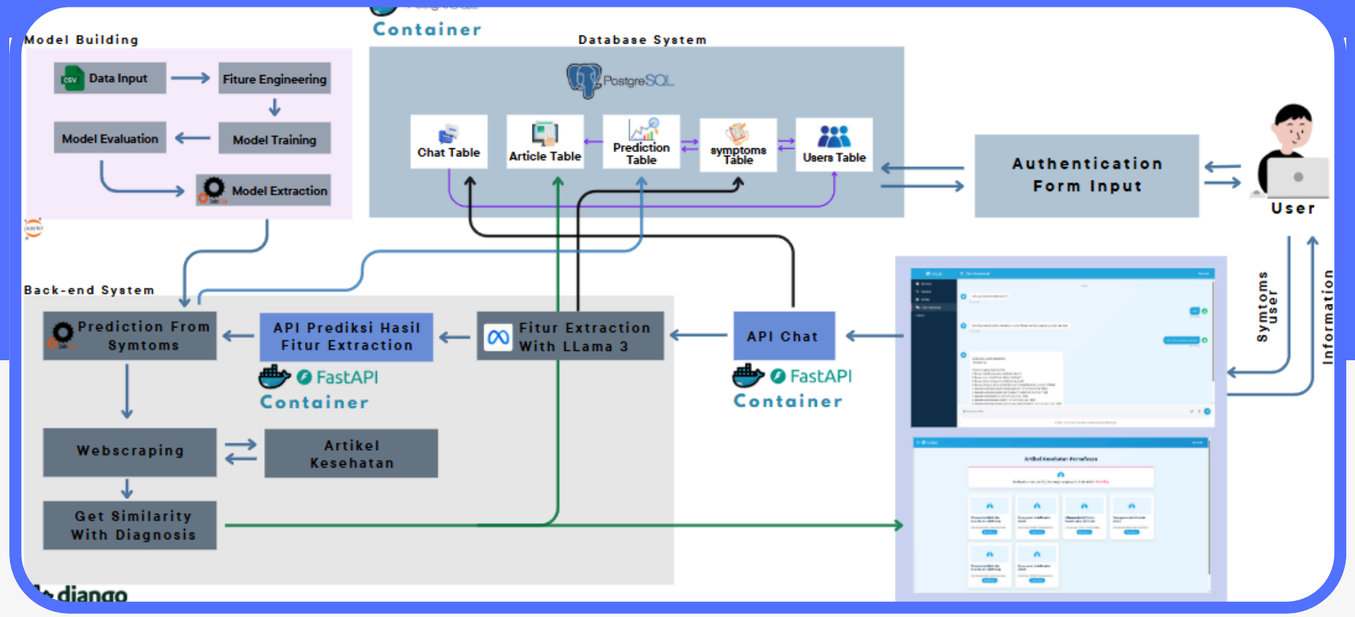
Penyakit saluran pernapasan merupakan gangguan pada organ pernapasan yang menyebabkan fungsinya tidak berjalan normal. Menurut WHO (2012), ratusan juta orang di dunia menderita penyakit ini, termasuk asma, PPOK, dan berbagai penyakit kronis lain yang sering tidak terdiagnosis dan kerap diabaikan. Dengan kemajuan teknologi, sistem berbasis kecerdasan buatan dapat membantu dalam prediksi penyakit berdasarkan gejala yang dilaporkan pasien, serta memberikan informasi edukatif terkait penyakit yang diprediksi yang dapat memudahkan pasien untuk memberikan gambaran awal atas penyakit yang sedang diderita.

TUJUAN

Mengembangkan website dengan fitur konsultasi pasien berbasis prediksi gejala, yang secara otomatis:

- Memprediksi kemungkinan penyakit pernapasan (Bronchitis, Flu, Cold, Pneumonia)
- Menyediakan artikel edukatif terkait penyakit yang diprediksi

SYSTEM DESIGN



Platform ini adalah layanan prediksi gejala dan konsultasi kesehatan berbasis Chatbot AI. Setelah login, pengguna dapat berinteraksi dengan Chatbot I-CLIC untuk menyampaikan gejala yang dirasakan. Sistem akan memprediksi kondisi kesehatan dan menyarankan artikel serta kasus serupa sebagai referensi. Teknologi di baliknya mencakup antarmuka web interaktif, Django sebagai backend, dan PostgreSQL untuk menyimpan data pengguna, gejala, serta hasil prediksi. Prediksi dilakukan oleh model LLM melalui FastAPI secara real-time. Sistem juga memiliki pipeline pembelajaran mesin yang terus dilatih, serta fitur web scraping untuk menambah referensi dari artikel dan kasus medis terkini.

DATA UNDERSTANDING

Dataset statistics

Number of variables	13
Number of observations	2000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	203.3 KiB
Average record size in memory	104.1 B

Variable types

Numeric	5
Categorical	7
Text	1

Dataset terdiri dari 2000 Baris dan 13 Variable, Dengan 5 variable numerik, 7 variable kategorikal, dan 1 variable text. Dataset tidak memiliki Missing value dan tidak ada yang terduplikat. Total ukuran dataset adalah sekitar 203.3 KiB.

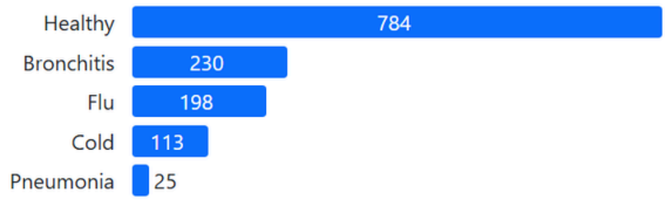
EXPLORATORY DATA ANALYSIS

DISTRIBUSI TARGET

Diagnosis

Categorical

Distinct	5
Distinct (%)	0.4%
Missing	0
Missing (%)	0.0%
Memory size	21.1 KiB



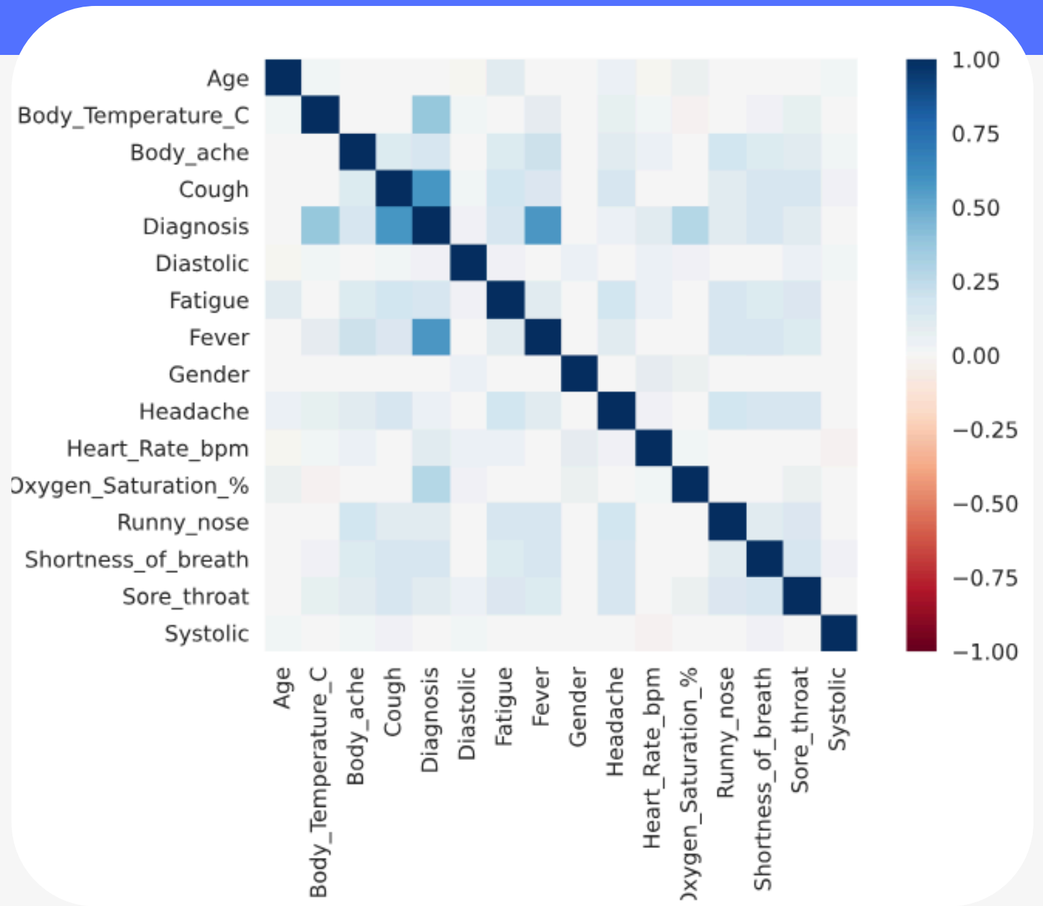
More details

Dari distribusi class dapat dilihat bahwa class healthy mendominasi data dengan 784 entri, jauh lebih tinggi dibandingkan kategori lainnya, sedangkan class pneumonia menjadi class minoritas dengan perbandingan sekitar 31 kali lipat dengan mayoritas. Ketidakseimbangan Kelas sangat terlihat karena class healthy hampir 3 akali lebih banyak dari total semua penyakit digabung. Untuk itu kondisi ini perlu diperhatikan agar model tidak bias terhadap kelas mayoritas .

EXPLORATORY DATA ANALYSIS

KORELASI VARIABEL

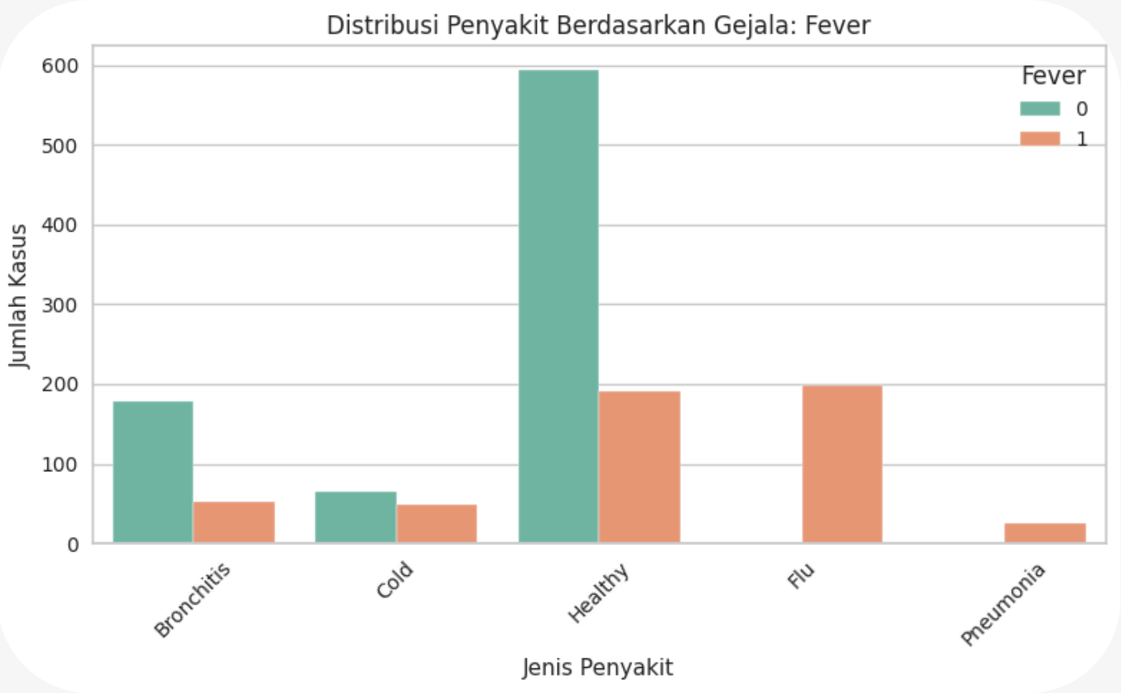
Dari analisis korelasi, ditemukan bahwa cough, Body Ache, dan Shortness of Breath memiliki keterkaitan yang cukup kuat dengan diagnosis. Di sisi lain, Oxygen Saturation menunjukkan korelasi negatif artinya, semakin rendah nilai saturasi oksigennya, semakin besar kemungkinan munculnya diagnosis tertentu. Selain itu, meskipun pengaruhnya tidak terlalu besar, variabel seperti Body Temperature, Fever, Headache, Heart Rate, dan Sore Throat juga tetap memiliki hubungan yang relevan.



EXPLORATORY DATA ANALYSIS

DISTRIBUSI PENYAKIT BERDASARKAN GEJALA

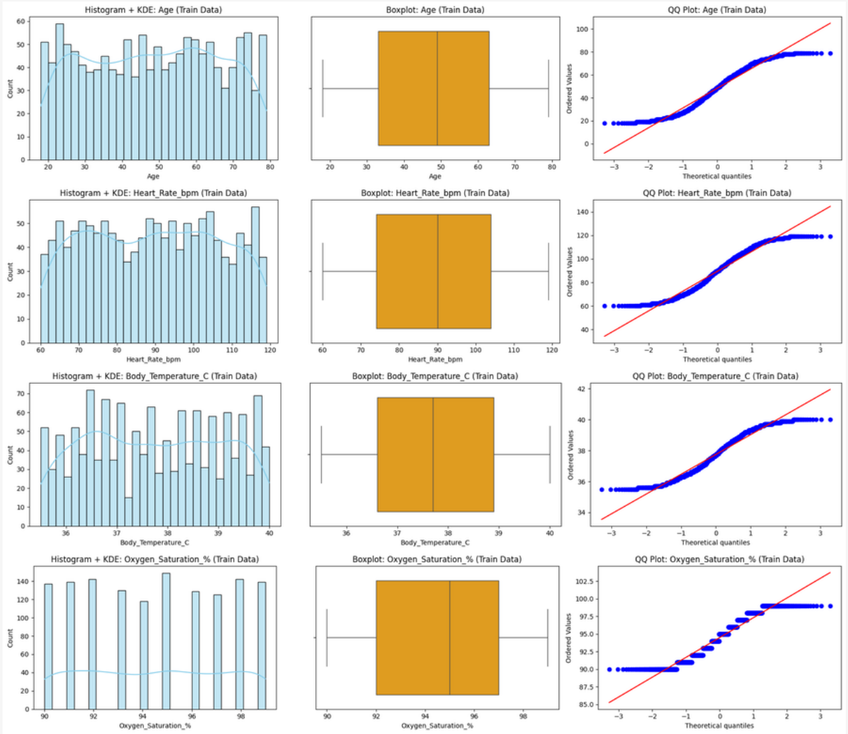
Berdasarkan grafik, gejala fever menunjukkan hubungan yang kuat dengan jenis penyakit. Hampir semua kasus flu dan pneumonia terjadi pada pasien yang mengalami demam (fever = 1), sedangkan mayoritas pasien healthy justru tidak memiliki demam (fever = 0). Perbedaan distribusi ini menunjukkan bahwa keberadaan demam sangat membantu membedakan antara pasien sehat dan yang sakit, sehingga gejala fever dianggap sangat berkorelasi dengan diagnosis penyakit.



EXPLORATORY DATA ANALYSIS

ANALISA NORMALITAS FITUR NUMERIC

dari visualisasi histogram, boxplot, dan QQ plot untuk variabel Age, Heart Rate, Body Temperature, dan Oxygen Saturation pada train data, dapat dipahami bahwa seluruh variabel tidak menunjukkan adanya outlier, terlihat dari boxplot yang tidak memiliki titik di luar whisker. Namun, distribusi semua variabel cenderung tidak normal. Variabel Age dan Oxygen Saturation jelas tidak normal karena bentuk distribusinya tidak simetris dan titik-titik pada QQ plot menyimpang jauh dari garis lurus. Body Temperature dan Heart Rate menunjukkan pola yang hampir simetris, tetapi QQ plot keduanya masih menyimpang di bagian ekor, sehingga tidak sepenuhnya normal. Secara keseluruhan, meskipun tidak ada outlier, distribusi data tidak mengikuti distribusi normal.



DATA PREPROCESSING

FITUR EXTRACTION

Blood_Pressure_mmHg
93/81
145/79
140/112
174/81
121/63

Systolic	Diastolic
93	81
145	79
140	112
174	81
121	63

Symptom_1	Symptom_2	Symptom_3
Runny nose	Body ache	Fever
Body ache	Shortness of breath	Runny nose
Cough	Fever	Sore throat
Fatigue	Fever	Sore throat
Headache	Fever	Cough

Runny_nose	Shortness_of_breath	Body_ache	Headache	Cough	Fever	Sore_throat	Fatigue
1	0	1	0	0	1	0	0
1	1	1	0	0	0	0	0
0	0	0	0	1	1	1	0
0	0	0	0	0	1	1	1
0	0	0	1	1	1	0	0

Feature extraction berguna untuk mengambil informasi penting dari tabel awal agar model lebih efisien dan akurat. Misalnya, kolom 'Blood_Pressure_mmHg' yang awalnya berupa string seperti "93/81" dipisahkan menjadi dua kolom numerik: Systolic dan Diastolic. Selain itu, dilakukan one-hot encoding untuk mengubah data kategorikal gejala menjadi format numerik, di mana setiap gejala unik menjadi kolom tersendiri dengan nilai 1 jika gejala ada, dan 0 jika tidak.

DATA PREPROCESSING

ENCODING

LABEL ENCODING

```
label_encoder = LabelEncoder()
X_train['Gender'] = label_encoder.fit_transform(X_train['Gender'])
X_val['Gender'] = label_encoder.transform(X_val['Gender'])
X_test['Gender'] = label_encoder.transform(X_test['Gender'])
X_train.info()
```

```
[19] diagnosis_encoding = {
        'Healthy': 1,
        'Bronchitis': 2,
        'Flu': 3,
        'Cold': 4,
        'Pneumonia': 5
    }

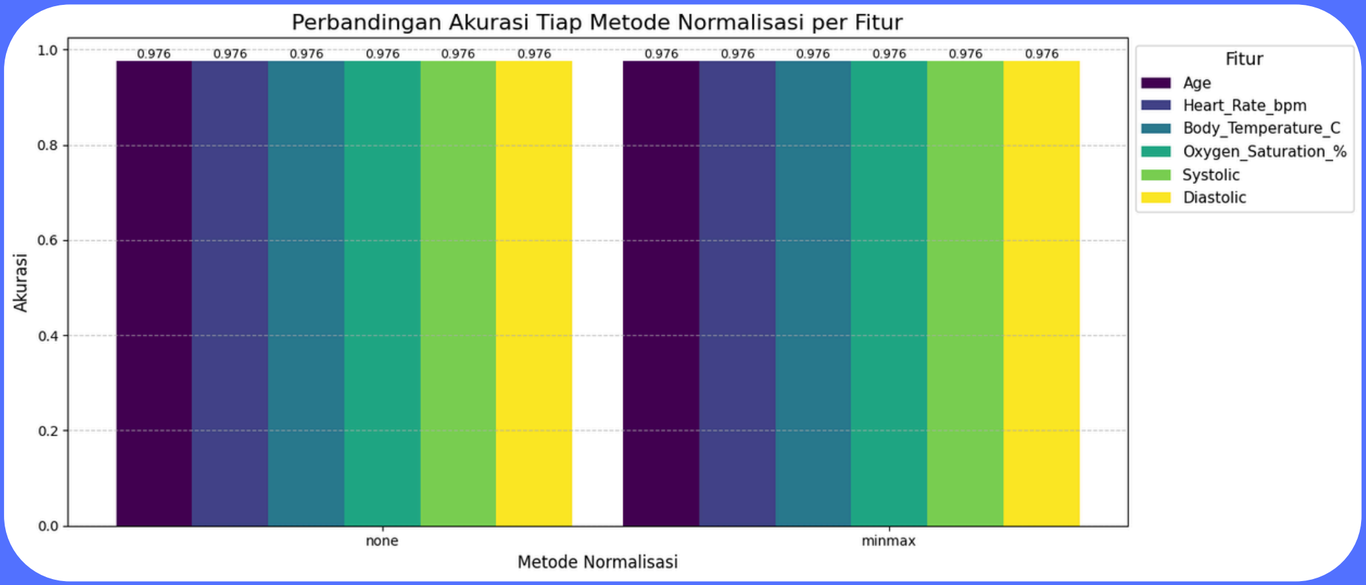
    y_train = y_train.map(diagnosis_encoding)
    y_test = y_test.map(diagnosis_encoding)
    y_val = y_val.map(diagnosis_encoding)

    class_counts = y_train.value_counts()
    print(class_counts)
```

Proses Label encoding untuk mengubah label kategorikal menjadi angka. seperti contoh, kami menggunakan fungsi ‘label_encoder’ untuk encoding Gender menjadi 0 untuk male dan 1 untuk female. gambar kedua adalah manual label encoding untuk kontrol penuh terhadap urutan label. karena Kami ingin memastikan urutan atau nilai label tetap sama di seluruh proses

DATA PREPROCESSING

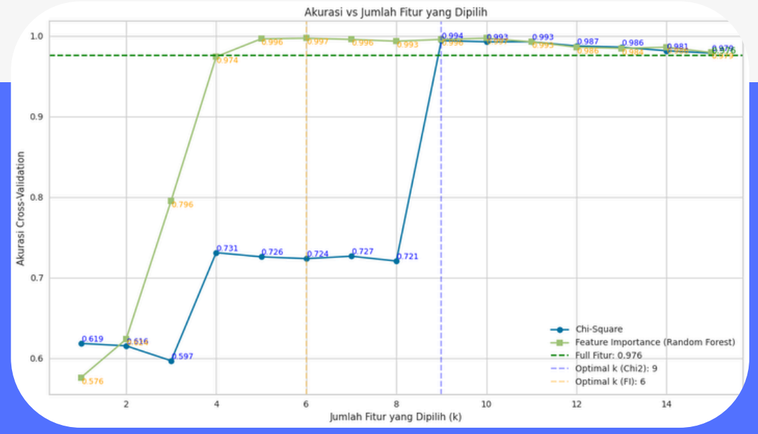
NORMALISASI



Dari grafik terlihat bahwa akurasi model tetap 0.976, baik dengan normalisasi Min-Max maupun tanpa normalisasi. Ini menunjukkan bahwa normalisasi tidak memengaruhi akurasi, dan model cukup robust terhadap skala data. Min-Max dipilih karena tidak menghasilkan nilai negatif, jadi aman untuk digunakan pada metode klasifikasi yang sensitif terhadap nilai -1.

DATA PREPROCESSING

FITUR SELECTION & IMPORTANCE




```
Classification Report - Chi-Square (Validation):
              precision    recall  f1-score   support

           1       1.00      1.00      1.00        80
           2       1.00      1.00      1.00        25
           3       0.96      1.00      0.98        27
           4       1.00      1.00      1.00        13
           5       1.00      0.80      0.89         5

    accuracy                           0.99       150
   macro avg       0.99      0.96      0.97       150
weighted avg       0.99      0.99      0.99       150

Classification Report - Feature Importance (Validation):
              precision    recall  f1-score   support

           1       1.00      1.00      1.00        80
           2       1.00      1.00      1.00        25
           3       0.96      1.00      0.98        27
           4       1.00      1.00      1.00        13
           5       1.00      0.80      0.89         5

    accuracy                           0.99       150
   macro avg       0.99      0.96      0.97       150
weighted avg       0.99      0.99      0.99       150

Classification Report - Full Fitur (Validation):
              precision    recall  f1-score   support

           1       0.99      1.00      0.99        80
           2       1.00      1.00      1.00        25
           3       0.84      1.00      0.92        27
           4       1.00      0.92      0.96        13
           5       0.00      0.00      0.00         5

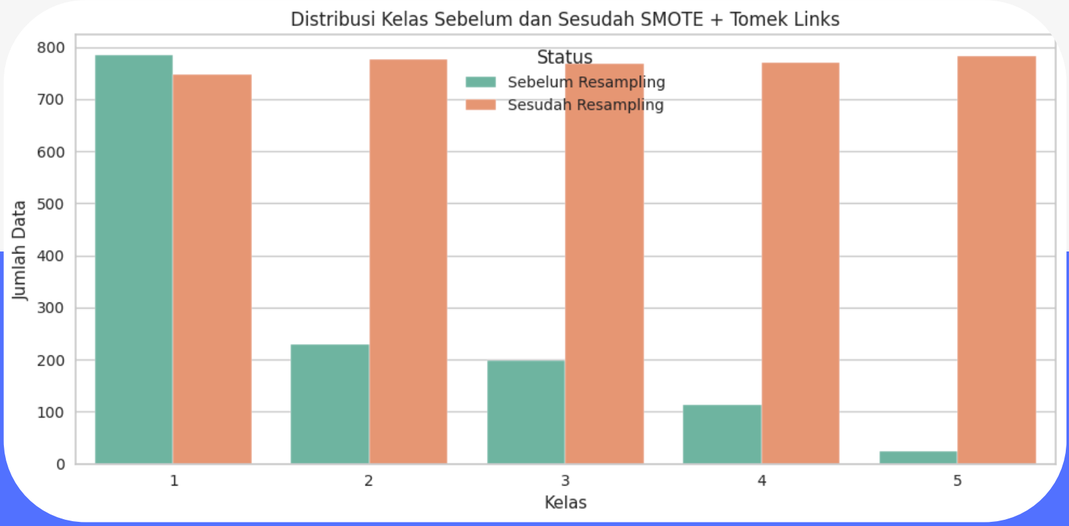
    accuracy                           0.96       150
   macro avg       0.77      0.78      0.77       150
weighted avg       0.93      0.96      0.94       150
```

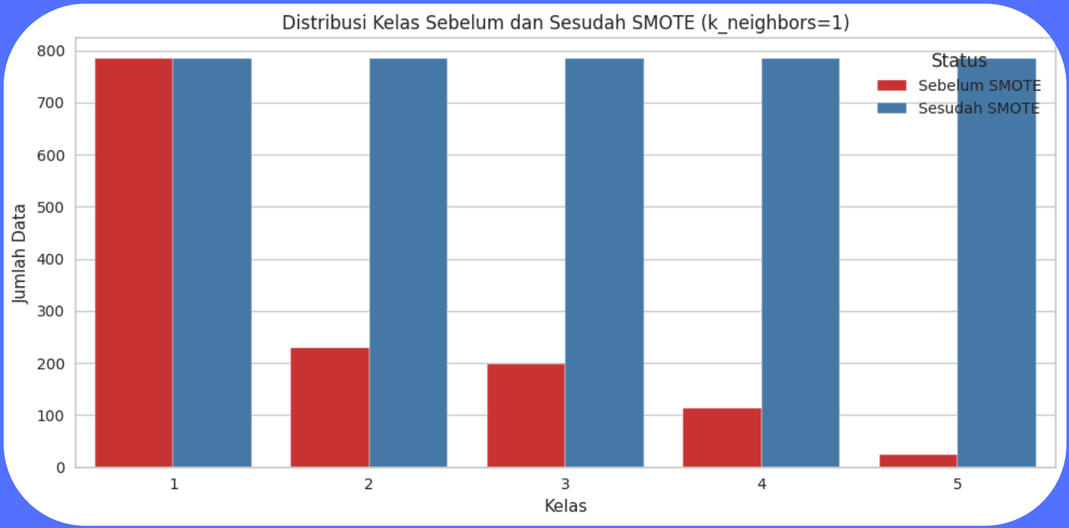
```
Jumlah fitur optimal berdasarkan Chi-Square: 9
Fitur yang dipilih berdasarkan Chi-Square: Index(['Age', 'Heart_Rate_bpm', 'Body_Temperature_C', 'Oxygen_Saturation_%',
       'Shortness_of_breath', 'Body_ache', 'Cough', 'Fever', 'Fatigue'],
      dtype='object')
Jumlah fitur optimal berdasarkan Feature Importance: 6
Fitur yang dipilih berdasarkan Feature Importance: Index(['Body_Temperature_C', 'Oxygen_Saturation_%', 'Cough', 'Fever',
       'Heart_Rate_bpm', 'Age'],
      dtype='object')
```

Metode Chi-Square dipilih karena menghasilkan akurasi tertinggi sebesar 0.994 saat menggunakan 9 fitur, melampaui akurasi model dengan full fitur. Fitur yang dipilih juga lebih relevan secara statistik dan berhasil meningkatkan kinerja pada kelas minoritas yang sebelumnya sulit dikenali. Model dengan Chi-Square lebih stabil dan efisien tanpa mengorbankan akurasi, sehingga cocok untuk sistem deteksi berbasis data medis. Selain itu, fitur yang dihasilkan lebih mudah diinterpretasikan untuk keperluan klinis dibandingkan hasil dari Feature Importance Random Forest.

DATA PREPROCESSING

IMBALANCE TREATMENT





- SMOTE dengan Tomek Links menambah data minoritas dan merapikan distribusi, menghapus sampel yang terlalu mirip. Awalnya, data tidak seimbang—kelas 1 memiliki 800 data, kelas 2 dan 3 hanya 200, kelas 4 sekitar 100, dan kelas 5 paling sedikit dengan 50. Setelah resampling, semua kelas mencapai 750–800 data, lebih seimbang dan bersih, mengurangi risiko overfitting.
- SMOTE dengan k_neighbors = 1 hanya menambah data berdasarkan satu tetangga terdekat tanpa pembersihan, menyamakan jumlah data setiap kelas menjadi 800. Namun, metode ini lebih rentan overfitting karena data sintetis terlalu mirip dengan data asli dan kemungkinan masih mengandung noise.

MODEL SELECTION AND TRAINING

MODELING WITH RANDOM FOREST

SMOTE-Tomek dan SMOTENN sama-sama memberikan hasil optimal dalam melatih model klasifikasi, dengan skor sempurna di setiap metrik evaluasi. Pada tahap validasi, SMOTE-Tomek tetap stabil, sementara SMOTENN sedikit menurun dengan akurasi 99,3% dan F1-score 95%, menunjukkan perbedaan dalam kemampuan mengenali pola baru. Dalam pengujian akhir, keduanya memiliki akurasi 99,8%, tetapi SMOTE-Tomek unggul dalam presisi dan keseimbangan prediksi. Secara keseluruhan, kedua metode efektif mengatasi ketimpangan data, namun SMOTE-Tomek lebih konsisten di semua tahap.

🔹 [TRAIN] Evaluation for SMOTENN
Accuracy: 1.0000, AUC: 1.0000, Recall: 1.0000

	precision	recall	f1-score	support
1	1.00	1.00	1.00	784
2	1.00	1.00	1.00	784
3	1.00	1.00	1.00	784
4	1.00	1.00	1.00	784
5	1.00	1.00	1.00	784
accuracy			1.00	3920
macro avg	1.00	1.00	1.00	3920
weighted avg	1.00	1.00	1.00	3920

🔹 [VALIDATION] Evaluation for SMOTENN
Accuracy: 0.9933, AUC: 1.0000, Recall: 0.9600

	precision	recall	f1-score	support
1	1.00	1.00	1.00	80
2	1.00	1.00	1.00	25
3	0.96	1.00	0.98	27
4	1.00	1.00	1.00	13
5	1.00	0.80	0.89	5
accuracy			0.99	150
macro avg	0.99	0.96	0.97	150
weighted avg	0.99	0.99	0.99	150

🔹 [TEST] Evaluation for SMOTENN
Accuracy: 0.9980, AUC: 1.0000, Recall: 0.9857

	precision	recall	f1-score	support
1	1.00	1.00	1.00	303
2	1.00	1.00	1.00	79
3	0.99	1.00	0.99	67
4	1.00	1.00	1.00	37
5	1.00	0.93	0.96	14
accuracy			1.00	500
macro avg	1.00	0.99	0.99	500
weighted avg	1.00	1.00	1.00	500

🔹 [TRAIN] Evaluation for SMOTE-TOMEK
Accuracy: 1.0000, AUC: 1.0000, Recall: 1.0000

	precision	recall	f1-score	support
1	1.00	1.00	1.00	747
2	1.00	1.00	1.00	777
3	1.00	1.00	1.00	768
4	1.00	1.00	1.00	769
5	1.00	1.00	1.00	783
accuracy			1.00	3844
macro avg	1.00	1.00	1.00	3844
weighted avg	1.00	1.00	1.00	3844

🔹 [VALIDATION] Evaluation for SMOTE-TOMEK
Accuracy: 1.0000, AUC: 1.0000, Recall: 1.0000

	precision	recall	f1-score	support
1	1.00	1.00	1.00	80
2	1.00	1.00	1.00	25
3	1.00	1.00	1.00	27
4	1.00	1.00	1.00	13
5	1.00	1.00	1.00	5
accuracy			1.00	150
macro avg	1.00	1.00	1.00	150
weighted avg	1.00	1.00	1.00	150

🔹 [TEST] Evaluation for SMOTE-TOMEK
Accuracy: 0.9980, AUC: 1.0000, Recall: 0.9857

	precision	recall	f1-score	support
1	1.00	1.00	1.00	303
2	1.00	1.00	1.00	79
3	0.99	1.00	0.99	67
4	1.00	1.00	1.00	37
5	1.00	0.93	0.96	14
accuracy			1.00	500
macro avg	1.00	0.99	0.99	500
weighted avg	1.00	1.00	1.00	500

MODEL SELECTION AND TRAINING

COMPARE MODEL

	Description	Value
0	Session id	42
1	Target	Diagnosis
2	Target type	Multiclass
3	Original data shape	(3994, 16)
4	Transformed data shape	(3994, 16)
5	Transformed train set shape	(3844, 16)
6	Transformed test set shape	(150, 16)
7	Numeric features	15
8	Rows with missing values	96.2%

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
rf	Random Forest Classifier	0.9995	0.9998	0.9995	0.9995	0.9995	0.9993	0.9994	0.3000
lightgbm	Light Gradient Boosting Machine	0.9995	1.0000	0.9995	0.9995	0.9995	0.9993	0.9994	1.4520
catboost	CatBoost Classifier	0.9995	1.0000	0.9995	0.9995	0.9995	0.9993	0.9994	5.7220
dt	Decision Tree Classifier	0.9992	0.9995	0.9992	0.9992	0.9992	0.9990	0.9990	0.0290

Tabel menunjukkan hasil pengujian model dengan PyCaret tanpa preprocessing. Data sudah dibagi menjadi latih dan uji. Random Forest dipilih karena performanya paling stabil, dengan akurasi 99,95%, AUC 0,9998, recall 99,92%, precision 99,98%, dan F1 score 99,95%. Meskipun butuh komputasi lebih tinggi dari Decision Tree, keunggulan akurasi dan konsistensinya menjadikannya model terbaik untuk diagnosis.

MODEL SELECTION AND TRAINING

HYPERPARAMETER TUNNING

Model Random Forest yang disetel dengan Optuna menunjukkan kinerja sangat baik, dengan akurasi sempurna (100%) di data latih dan uji. Semua metrik evaluasi, seperti ROC AUC, precision, recall, dan F1-score, juga mencapai nilai maksimal. Meski ada tanda overfitting pada data latih, hasil validasi tetap stabil, menandakan model mampu mengenali pola baru secara efektif. Proses tuning menggunakan data validasi turut memastikan model tidak sekadar menghafal data. Dalam konteks medis, keakuratan di atas 90% ini sangat penting dan membuat model cukup andal untuk membantu klasifikasi dan pengambilan keputusan klinis.

```
Best Hyperparameters for Random Forest: {'n_estimators': 262, 'criterion': 'entropy', 'max_depth': 10, 'min_samples_split': 5, 'min_samples_leaf': 2, 'bootstrap': True}
ROC AUC on testing set: 1.0

Classification Report (Testing Set):
              precision    recall  f1-score   support

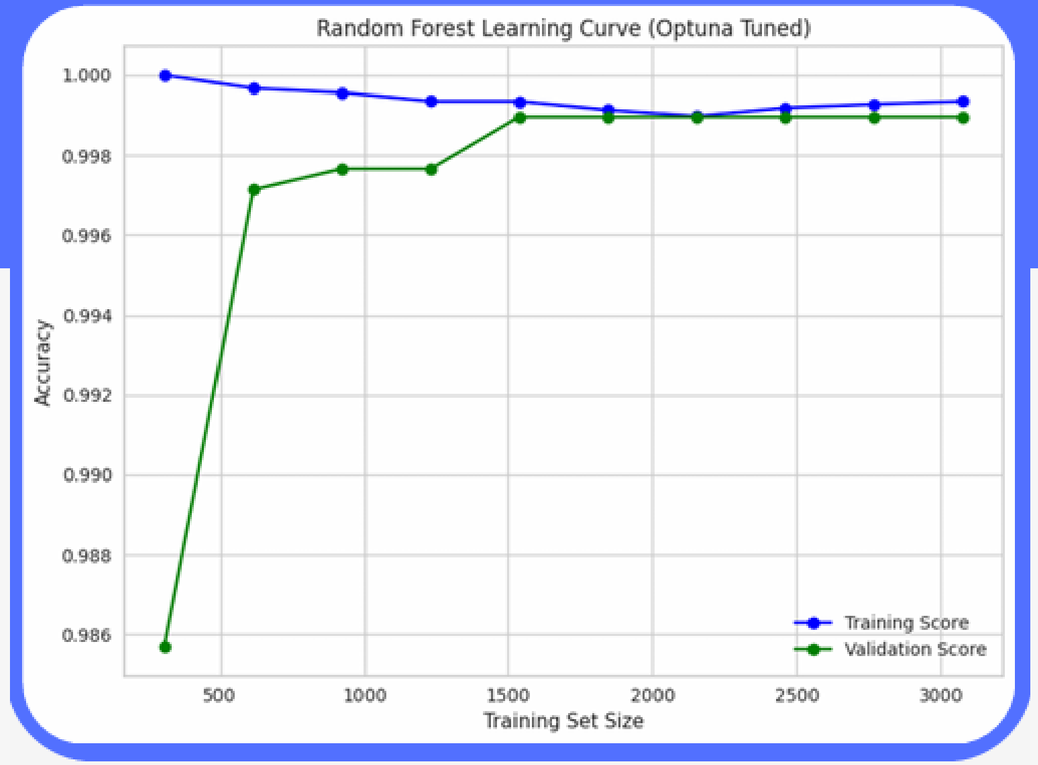
           1       1.00      1.00      1.00       303
           2       1.00      1.00      1.00        79
           3       1.00      1.00      1.00        67
           4       1.00      1.00      1.00        37
           5       1.00      1.00      1.00        14

    accuracy                           1.00       500
   macro avg       1.00      1.00      1.00       500
weighted avg       1.00      1.00      1.00       500
```

MODEL EVALUATION

LEARNING CURVE

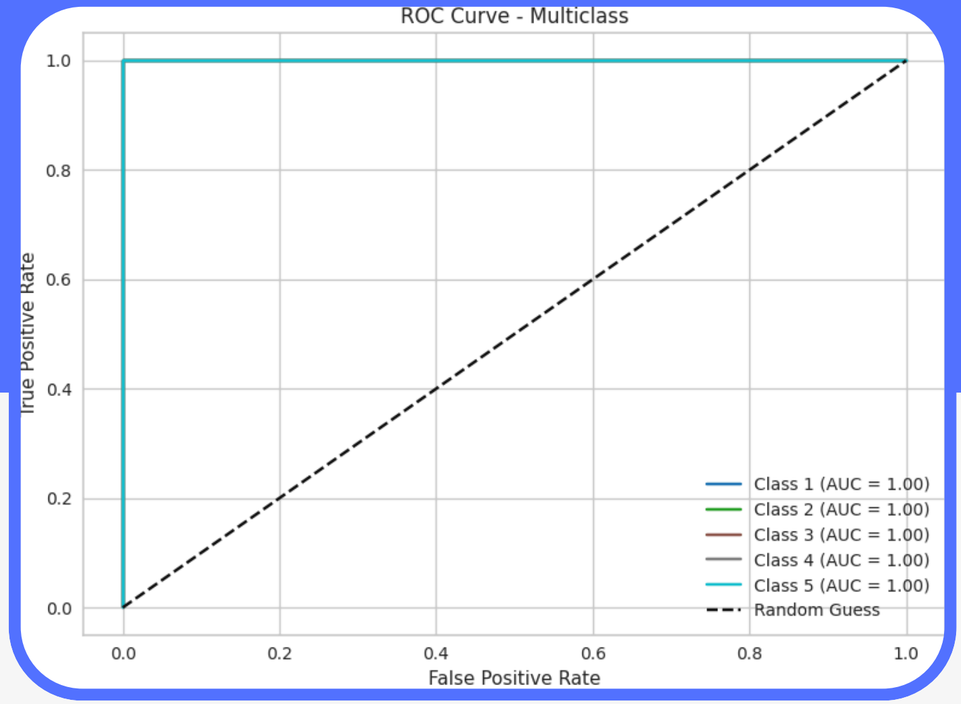
Learning Curce model Random Forest yang melalui Optuna Tuned menunjukkan dengan peningkatan ukuran training set, baik skor pelatihan maupun skor validasi cenderung stabil dan tinggi. Meskipun pada awal plot menunjukan skor validasi jauh lebih rendah daripada skor train, hal ini secara tidak langsung menandakan terjadinya underfitting. Namun, seiring bertambahnya ukuran training set, skor validasi meningkat mendekati skor train hingga mencapai akurasi di atas 0.99. Jarak yang sempit dan stabil antara kedua kurva pada ukuran training set 1500 hingga 3000 menunjukkan bahwa model memiliki bias yang rendah dan varians yang rendah. Untuk itu dapat disimpulkan bahwa kinerja yang kuat dan kemampuan generalisasi yang baik yang signifikan karena peningkatan data.



MODEL EVALUATION

CURVA ROV

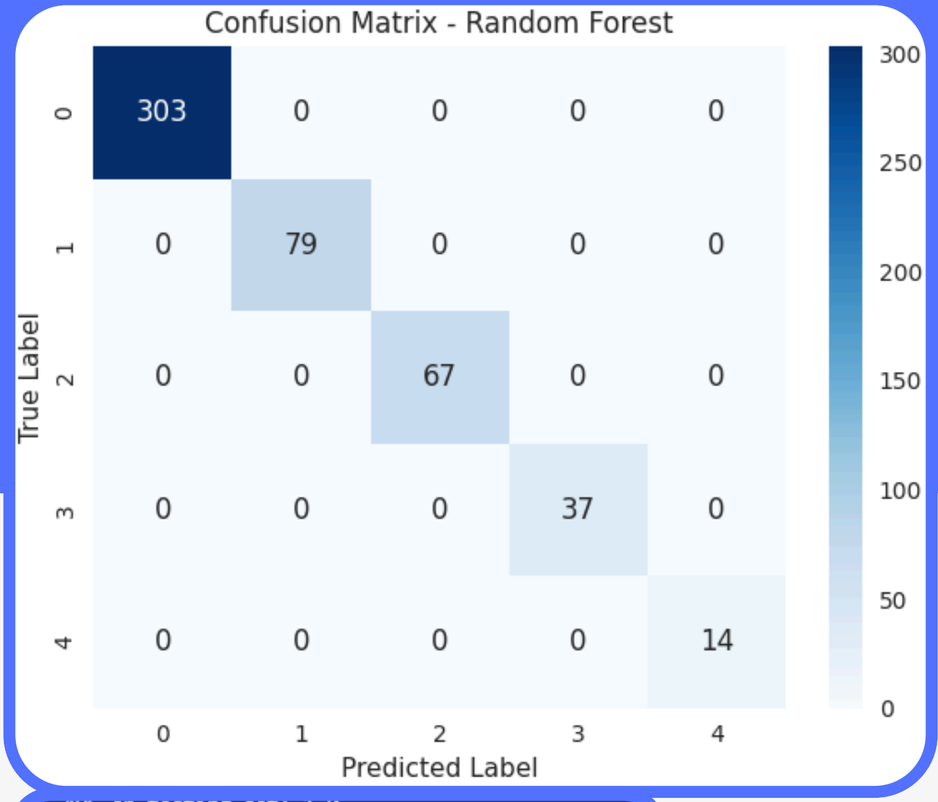
Kurva ROC menunjukkan bahwa model memiliki kinerja yang sempurna untuk setiap Class, dari 1 hingga Class 5 dengan nilai Area Under the Curve (AUC) sebesar 1.00 untuk semua kelas. Ini menunjukan bahwa model mampu membedakan antara kelas positif dan negatif dengan sempurna pada semua ambang batas, jauh lebih baik daripada tebakan acak.



MODEL EVALUATION

MATRIC EVALUATION

Confusion matrix dari model Random Forest pada testing set menunjukkan bahwa semua prediksi benar, di mana setiap instans dari setiap class diklasifikasikan dengan tepat ke kelasnya sendiri, tanpa adanya kesalahan klasifikasi. Ini dikonfirmasi oleh clasification report yang menunjukkan presisi, recall, dan F1-score sebesar 1.00 untuk setiap kelas, serta akurasi keseluruhan sebesar 1.00. Selain itu, ditambah dengan ROC AUC sebesar 1.0 pada testing set, menunjukan bahwa model ini sangat andal dan mampu mengklasifikasikan data baru dengan akurasi maksimal.




```
C AUC on testing set: 1.0

Classification Report (Testing Set):
              precision    recall  f1-score   support

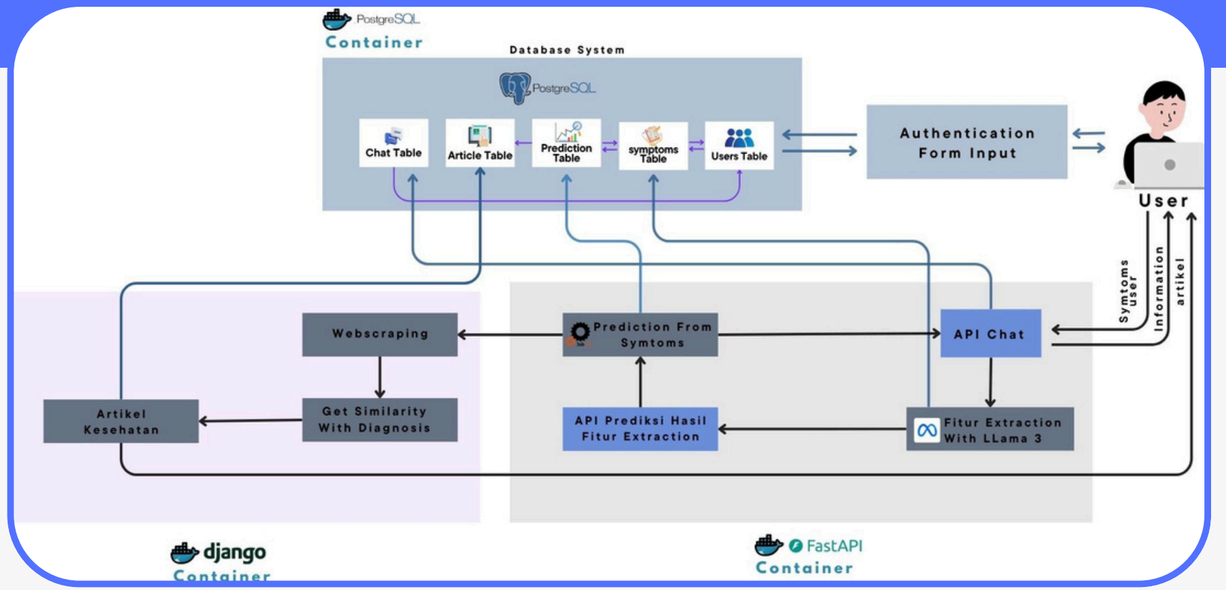
           1       1.00      1.00      1.00       303
           2       1.00      1.00      1.00        79
           3       1.00      1.00      1.00        67
           4       1.00      1.00      1.00        37
           5       1.00      1.00      1.00        14

    accuracy                           1.00       500
   macro avg       1.00      1.00      1.00       500
ighted avg       1.00      1.00      1.00       50
```

DEPLOYMENT

DOCKER

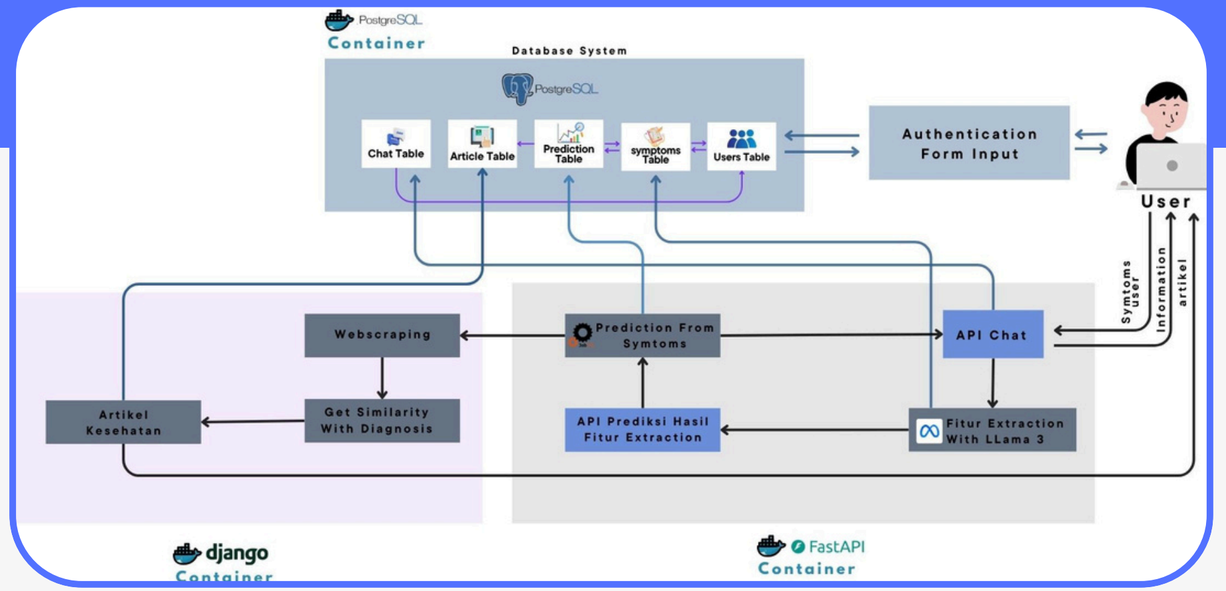
Proyek ini menggunakan Docker Compose untuk mengelola seluruh layanan dalam container yang terisolasi. Tiga container utama yaitu: Django (frontend), FastAPI (backend), dan PostgreSQL (database). Docker Compose mempermudah proses build, up, dan sinkronisasi antar layanan hanya dengan satu perintah. Dengan pendekatan ini, pengembangan menjadi lebih konsisten dan lingkungan runtime bisa direplikasi dengan mudah. Setiap container berkomunikasi melalui jaringan internal Docker untuk keamanan dan efisiensi. Hal ini juga mendukung deployment yang scalable dan portabel di berbagai platform.



DEPLOYMENT

DJANGO

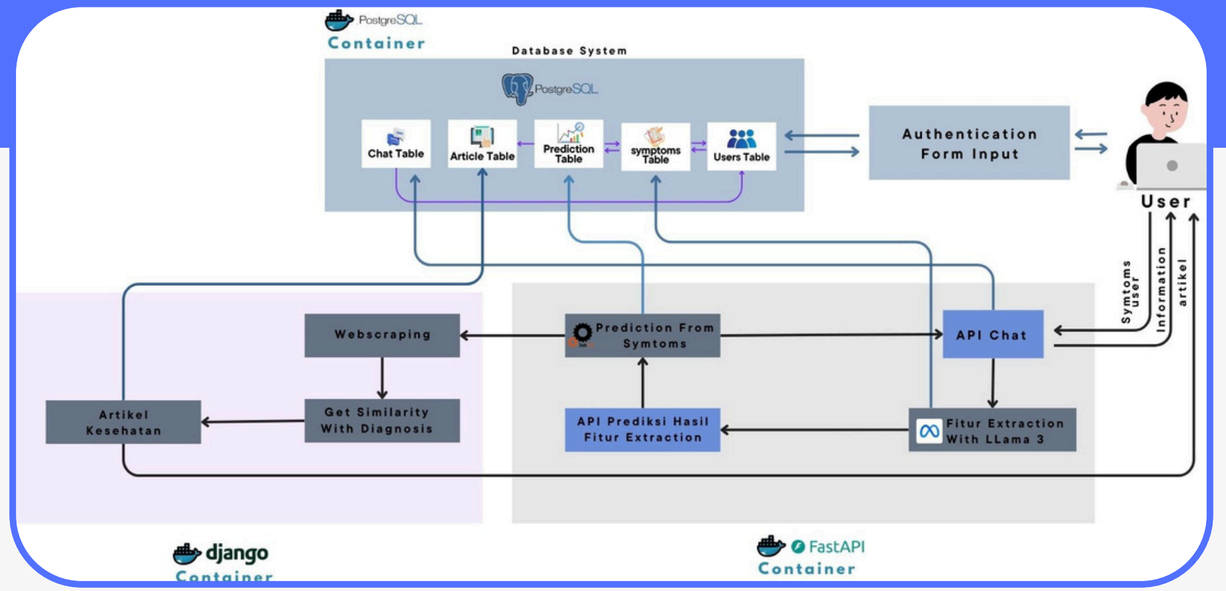
Django digunakan sebagai framework frontend dan sistem autentikasi pengguna. Pengguna melakukan registrasi, login, dan interaksi awal melalui form berbasis Django. Django juga menjalankan proses web scraping artikel kesehatan dari internet. Hasil scraping disimpan di database dan digunakan untuk pencocokan dengan hasil diagnosis. Antarmuka pengguna menampilkan hasil prediksi, riwayat chat, dan saran artikel secara interaktif. Seluruh modul frontend dibungkus dalam Django container untuk integrasi dengan sistem lainnya.



DEPLOYMENT

FAST API

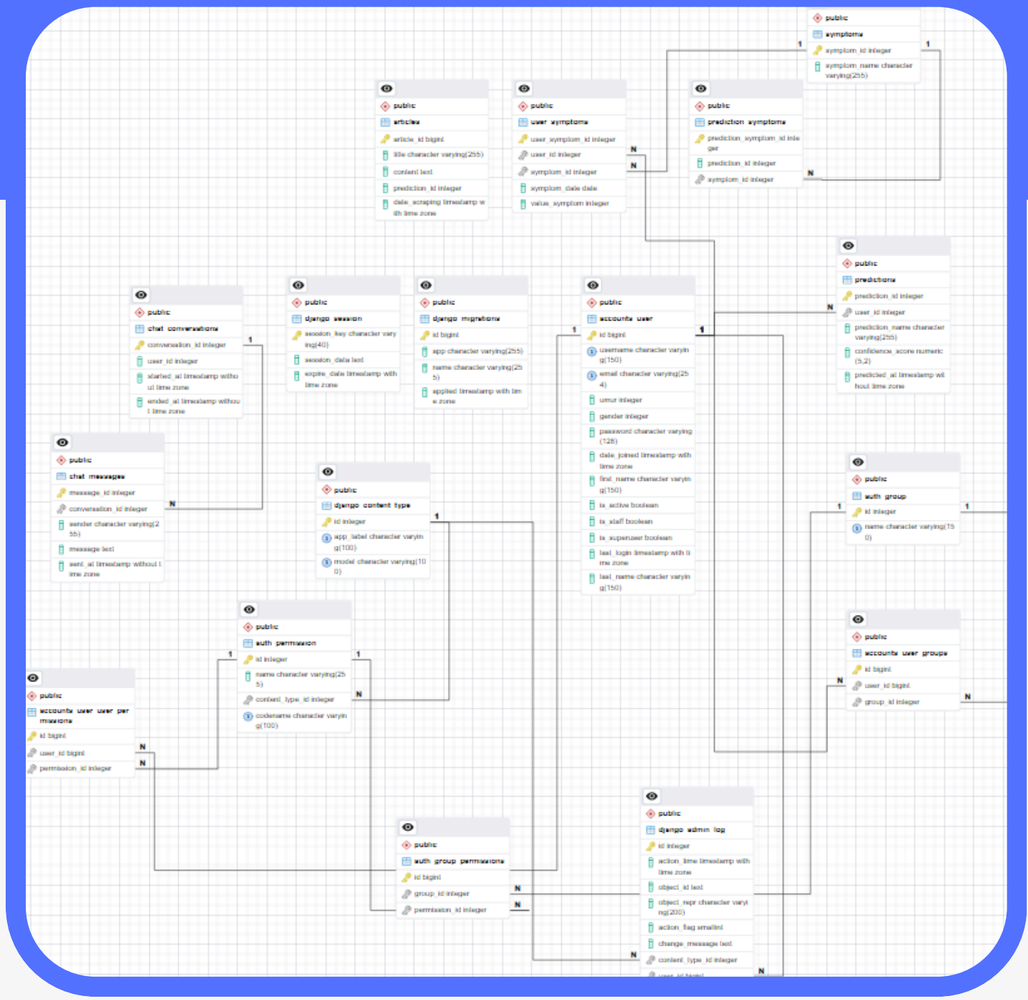
FastAPI bertugas sebagai backend yang menangani pemrosesan gejala dan prediksi penyakit. Input dari user dikirim ke API untuk dilakukan feature extraction menggunakan LLM. Fitur yang diperoleh diproses oleh model machine learning untuk menghasilkan prediksi. Hasil prediksi serta fitur disimpan dalam Prediction Table dan Symptoms Table. FastAPI juga menyediakan endpoint API Chat untuk interaksi chatbot dengan user. Proses ini berjalan dalam FastAPI container yang terhubung langsung ke database dan frontend.



DEPLOYMENT

POSTGRESQL

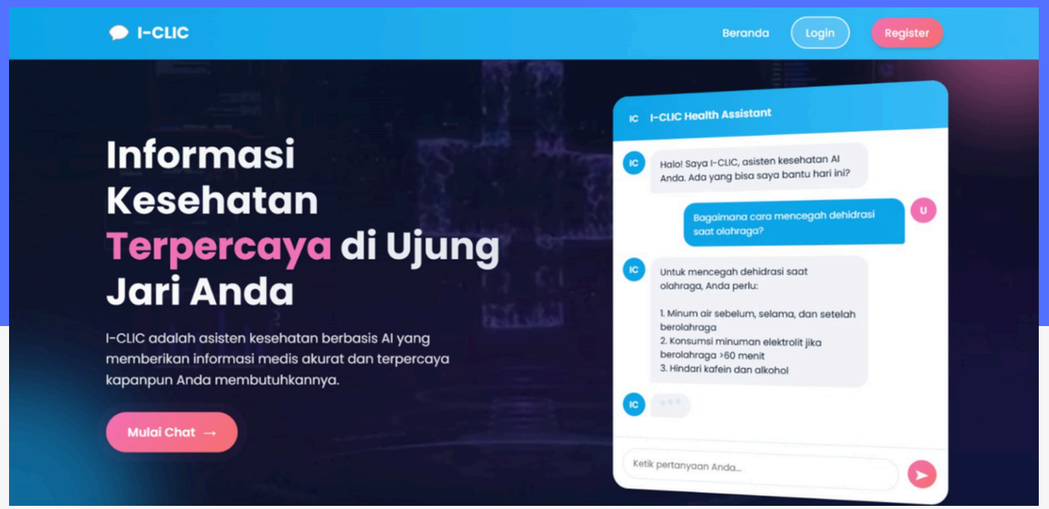
PostgreSQL digunakan sebagai sistem manajemen basis data relasional yang menyimpan seluruh data aplikasi secara terstruktur dan saling terhubung. Struktur tabel mencakup informasi pengguna pada tabel accounts_user, data gejala (symptoms dan user_symptoms), hasil prediksi (predictions dan prediction_symptom), serta riwayat chat (chat_conversation dan chat_message). Relasi antar tabel dirancang secara normal untuk mendukung integritas referensial dan efisiensi kueri, seperti foreign key antara user_symptoms ke tabel symptoms dan accounts_user. Sistem juga mengadopsi fitur Django default seperti tabel grup dan permission untuk pengelolaan otorisasi pengguna. Dengan skema ini, data dapat dikelola dengan aman, mudah diakses oleh backend FastAPI dan frontend Django.



FRONT-END

HOME PAGE

Halaman utama aplikasi ini secara singkat menjelaskan layanan asisten kesehatan berbasis kecerdasan buatan (AI) yang menyediakan informasi medis yang akurat. Pengguna dapat masuk (Login), mendaftar(Register) dan beranda itu membuat halaman ke refresh, atau mengobrol dengan chatbot dengan mengklik fitur “Mulai Chat”. Bagian kanan menampilkan tampilan chatbot dan komunikasi pengguna dengan asisten AI.



FRONT-END

LOGIN & REGISTER

Fitur register memungkinkan pengguna baru untuk membuat akun dengan mengisi data seperti nama, email, password, umur, dan gender. Setiap email harus unik dan tidak boleh sama dengan email pengguna lain untuk menjaga integritas data. Informasi gender dan umur yang dikumpulkan saat registrasi juga dimanfaatkan sebagai atribut dalam proses prediksi sistema.

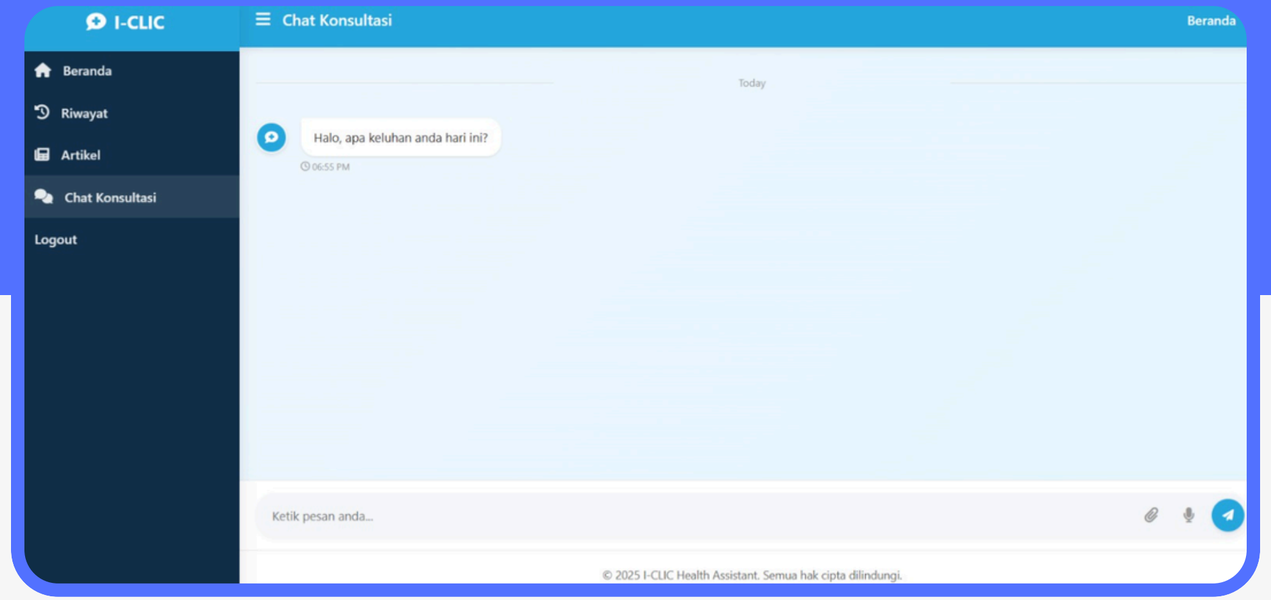
Fitur login digunakan untuk mengautentikasi pengguna yang telah terdaftar agar dapat mengakses sistem secara aman dengan menggunakan email dan password yang telah disimpan sebelumnya.



FRONT-END

CHATBOT

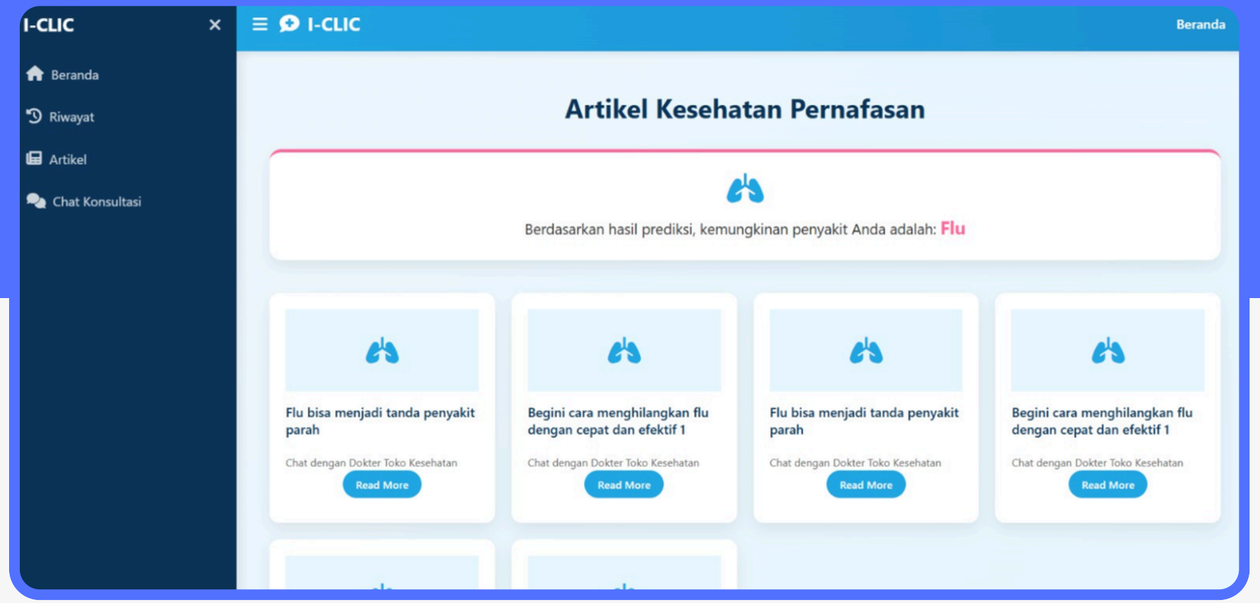
tampilan fitur chat konsultasi di sebelah kanan layar berfungsi sebagai tempat utama bagi pengguna untuk berinteraksi langsung dengan chatbot. Melalui fitur ini, pengguna bisa menyampaikan keluhan atau menanyakan hal-hal yang berkaitan dengan kesehatan mereka. Saat pertama kali dibuka, chatbot akan menyapa dengan pertanyaan seperti, "Halo, apa keluhan Anda hari ini?", dan hasil dari prediksi chat konsultasi tersebut akan ter update datanya di riwayat dan memberikan artikel yang sesuai prediksi penyakit nya



FRONT-END

ARTIKEL KESEHATAN

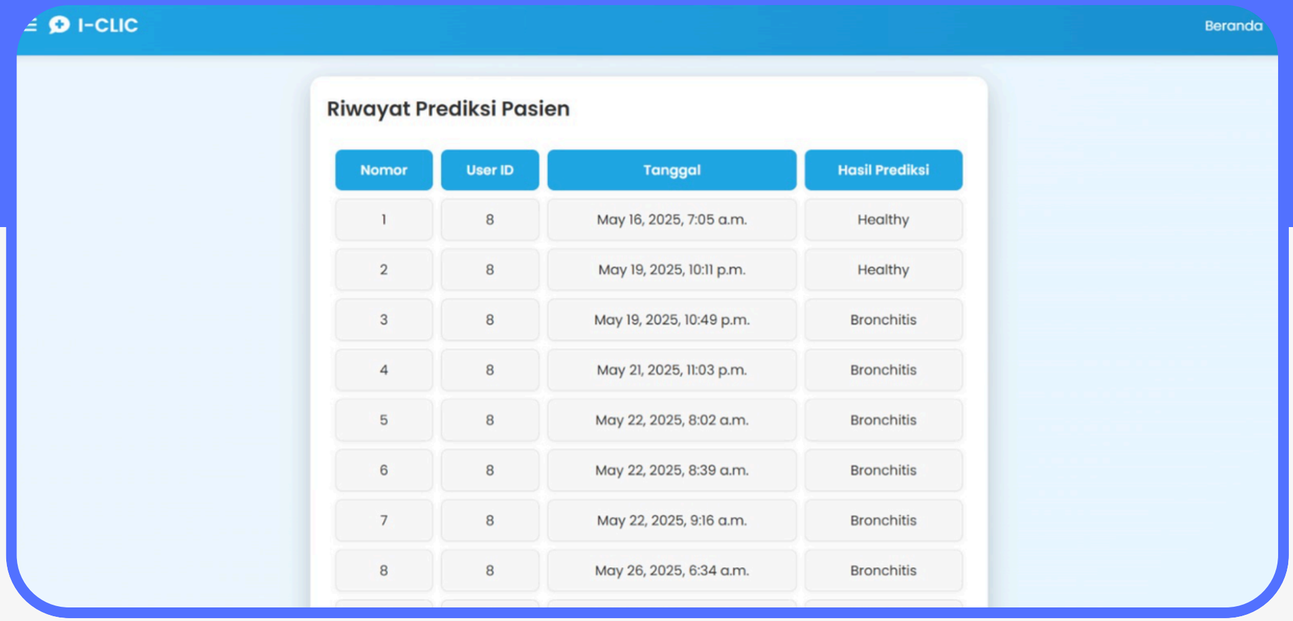
Artikel dalam aplikasi I-CLIC Health Assistant direkomendasikan berdasarkan hasil konsultasi chat dan diperoleh melalui scraping dari sumber terpercaya. Dengan pendekatan ini, pengguna mendapatkan informasi yang relevan, terkini, dan sesuai dengan keluhan mereka.



FRONT-END

RIWAYAT KESEHATAN

Fitur Riwayat dalam aplikasi I-CLIC Health Assistant menyimpan setiap prediksi dari chatbot dan mengurutkannya berdasarkan waktu serta tanggal. Pengguna dapat dengan mudah meninjau kembali penyakit yang pernah dialami.



CONCLUSION & RECOMMENDATION

CONCLUSION



I-CLIC atau Intelegent Clinic Care merupakan sebuah sistem deteksi penyakit ISPA berbasis layanan konsultasi chatbot yang mengintegrasikan teknologi NLP, machine learning, dan platform literasi kesehatan. Sistem ini memungkinkan pasien untuk melakukan konsultasi kesehatan secara interaktif melalui percakapan alami, yang kemudian diproses untuk mendeteksi kemungkinan gejala ISPA serta memberikan edukasi mengenai gaya hidup dan gizi yang sesuai. Sistem diuji dengan berbagai algoritma prediksi berbasis Tree untuk memilih metode dengan performa optimal dalam menganalisis data kategorikal dan numerik secara bersamaan.

Dalam tahap implementasi, sistem terbukti mampu melakukan klasifikasi penyakit dengan baik meskipun dihadapkan pada tantangan seperti ketidakseimbangan kelas dan variasi input bahasa pengguna. Sistem literasi berupa artikel penunjang dipilih berdasarkan tingkat similarity yang paling tinggi terhadap setiap class, sehingga artikel yang disajikan merupakan artikel penunjang yang relevan.

CONCLUSION & RECOMMENDATION

RECOMMENDATION



PENERAPAN LUAS PADA DAERAH TERPENCIL

Mengingat keterbatasan akses layanan kesehatan di daerah kepulauan dan terpencil, sistem ini sangat potensial untuk diimplementasikan sebagai layanan digital health berbasis komunitas, khususnya untuk skrining awal dan edukasi kesehatan.

KOLABORASI DENGAN INSTITUSI MEDIS

Untuk meningkatkan akurasi dan legalitas diagnosa, direkomendasikan agar sistem ini bekerja sama dengan tenaga medis atau lembaga kesehatan sebagai bagian dari program telemedisin berbasis kecerdasan buatan.

STABILISASI PERFORMA APLIKASI

Untuk menjaga konsistensi dan responsivitas sistem, diperlukan penggunaan API LLM dengan performa tinggi, seperti dari OpenAI, yang telah terbukti andal dalam menangani permintaan dalam jumlah besar dan kompleksitas bahasa alami.

DEMONSTRASI PROJECT





TERIMA KASIH

PRESENT BY

GITHUB LINK