WoMAI

WEARABLE OPERATIONAL MACHINE AGENTIC AI



Disusun Oleh:
DOAIBU

DAFTAR ISI

DAFTAR ISI ..... **i**
DAFTAR GAMBAR ..... **ii**
DAFTAR TABEL ..... **iii**
I. PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Tujuan 2
1.4 Manfaat 3
II. METODOLOGI **3**
2.1 Alur Pengambilan Data & Integrasi Hardware 4
2.2 Alur Pengembangan Model AI 6
2.2.1 Model Klasifikasi Kegagalan Mesin 6
2.2.2 Model Prediksi Kegagalan Mesin 6
2.3 Alur Integrasi Model AI 7
III. HASIL DAN PEMBAHASAN **8**
3.1 Evaluasi Model AI 8
3.1.1 Model Klasifikasi Kegagalan Mesin 8
3.1.2 Model Prediksi Kegagalan Mesin 9
3.1.3 Cause Analysis LLM 10
3.1.4 Suggestion for Improvement 10
3.2 Sistem Website 11
3.3 Sistem Hardware IoT 12
KESIMPULAN & RENCANA PENGEMBANGAN **13**
4.1 Rencana Pengembangan 13
4.2 Kesimpulan 13
LAMPIRAN **16**
Lampiran 1. Tampilan Website WoMAI 16
Lampiran 2. Full PDF Report 19
Lampiran 3. ERD System 21
Lampiran 4. DFD System 21
Lampiran 5. Bisnis Model Canvas 22

DAFTAR GAMBAR

Gambar 1. Diagram Arsitektur WoMAI....3
Gambar 2. Flowchart Pengambilan Data & Integrasi Hardware WoMAI....4
Gambar 3. Grafik Batang Distribusi Kelas....5
Gambar 4. Alur Pengembangan Model Klasifikasi Kegagalan Mesin....6
Gambar 5. Alur Pengembangan Model Horizon Prediksi Kegagalan Mesin....7
Gambar 6. Alur Integrasi Model AI....8
Gambar 7. Wiring Sistem Hardware....12
Gambar 8. Perangkat Hardware....12
Gambar 9. Landing page WoMAI....16
Gambar 10. Login page....16
Gambar 11. Register page....16
Gambar 12. Machine list page....17
Gambar 13. Machine Copilot WoMAI....17
Gambar 14. AI Diagnosis (Healthy)....17
Gambar 15. Report Page....17
Gambar 16. History Page....18
Gambar 17. AI Diagnosis (Failure)....18
Gambar 18. Report Document....18
Gambar 19. Knowledge Base Page....18
Gambar 20. What-if Chatbot....19
Gambar 21. SOP Chatbot....19
Gambar 22. Machine Condition Report, halaman 1: ringkasan informasi laporan dan kondisi rata-rata mesin....20
Gambar 23. Machine Condition Report, halaman 2: prediksi risiko kegagalan, kontribusi fitur, dan diagnosis AI....20
Gambar 24. Machine Condition Report, halaman 3: prosedur penanganan sesuai SOP berdasarkan manual servis....20
Gambar 25. Machine Condition Report, halaman 4: estimasi biaya komponen, log kondisi mesin, dan ringkasan laporan....20
Gambar 26. Machine Condition Report, halaman 5: rekomendasi tindakan operator dan jadwal pemeriksaan lanjutan....20
Gambar 27. Entity Relationship Diagram....21
Gambar 28. DFD System Level 0....21
Gambar 29. DFD System Level 1....22
Gambar 30. Market Size Analysis....22

DAFTAR TABEL

Tabel 1. Analisis Deskriptif Variabel..... 5
Tabel 2. Hasil model RandomSearchCV.....8
Tabel 3. Hasil model optuna TPE.....9
Tabel 4. Ringkasan hasil prediksi kegagalan.....9
Tabel 5. Perbandingan model..... 10
Tabel 6. Uji Konsistensi Suggestion.....11
Tabel 7. Keterangan Prototipe Tampilan Aplikasi..... 16
Tabel 8. Asumsi dan Segmentasi Pasar.....24

I. PENDAHULUAN

1.1 Latar Belakang

Di era Industri 4.0, optimalisasi operasi *smart manufacturing* menjadi salah satu faktor penting dalam menjaga efisiensi dan keberlangsungan proses produksi. Dalam industri, penggunaan mesin *milling* berkontribusi 20,27% terhadap perekonomian nasional dan disebut sebagai basis industri manufaktur terbesar di ASEAN (Wijayanto et al., 2025). Mesin *milling* banyak dimanfaatkan untuk memproduksi komponen dan membuat lubang pada benda kerja, terutama di industri *aerospace*, otomotif, *mold* and *die*, serta manufaktur mekanik lainnya (Rahul et al., 2021). Ketergantungan produksi pada mesin membuat keandalan operasional menjadi penting karena unplanned downtime dapat menghambat proses produksi dan menimbulkan kerugian besar. Berdasarkan laporan *True Cost of Downtime*, kerugian akibat berhentinya operasional mesin rata-rata mencapai US$260 *million* per jam di berbagai sektor manufaktur (Siemens, 2024). Dampak tersebut juga terlihat pada PT Nusantara Plantation Indonesia, yang mencatat rata-rata *unplanned downtime* sebesar 39,8 jam per bulan dan menyebabkan kehilangan produksi sekitar 394 ton CPO atau setara Rp2,36 miliar pendapatan per bulan (Hilman et al., 2023). Hal ini menunjukkan bahwa pencegahan *unplanned downtime* menjadi aspek penting untuk menjaga kontinuitas dan efisiensi proses produksi yang berdampak langsung ada finansial perusahaan tersebut.

Selain berdampak pada kontinuitas produksi, kondisi mesin dan peralatan juga berkaitan dengan keselamatan kerja. Pada 2023, sebanyak 32% kecelakaan kerja non-fatal di Uni Eropa terjadi di situs industrial, dengan sektor manufaktur menyumbang angka tertinggi (80,9%) untuk kecelakaan di area kerja stasioner (Eurostat, 2023). Permasalahan keandalan mesin juga masih ditemukan pada industri manufaktur di Indonesia. Penelitian pada mesin CNC Milling menunjukkan nilai OEE rata-rata sebesar 83,83%, dengan *downtime losses* menyumbang 22,93% dari total kerugian (Mustofa et al., 2025). Kondisi tersebut menunjukkan perlunya pemeliharaan yang mampu mengidentifikasi potensi kegagalan sebelum terjadi sehingga downtime dapat ditekan dan keandalan mesin tetap terjaga.

Sejalan dengan kebutuhan tersebut, pemanfaatan *artificial intelligence* mulai dikembangkan untuk mendeteksi potensi kerusakan mesin secara dini. Penelitian oleh Aulia dan kawan kawan pada 2025, menerapkan metode *naïve bayes* dan *decision tree* untuk mengklasifikasikan tingkat risiko kerusakan mesin dan menentukan apakah tindakan preventif diperlukan berdasarkan data historis mesin (Aulia et al., 2025). Namun, penelitian tersebut masih berfokus pada hasil klasifikasi dan belum memberikan penjelasan mengenai faktor yang mempengaruhi risiko maupun rekomendasi tindakan berdasarkan kondisi mesin. Keterbatasan tersebut menjadi dasar pengembangan Wearable Operational Machine Agentive AI (WoMAI) yang tidak hanya memprediksi kegagalan mesin berdasarkan model klasifikasi machine learning, tetapi juga memberikan early warning potensi kegagalan dalam 10 menit ke depan dengan model horizon, menjelaskan faktor yang mempengaruhi prediksi menggunakan SHAP, serta memberikan rekomendasi penanganan berdasarkan kasus historis dan dokumen manual mesin. Untuk mendukung rekomendasi tersebut, WoMAI secara otomatis mengekstraksi dan mengolah isi buku pedoman serta manual mesin menjadi knowledge base yang tersimpan dalam database dan dapat digunakan untuk pencarian informasi oleh sistem Retrieval Augmented Generation (RAG). WoMAI juga dilengkapi chatbot Agentic AI yang memungkinkan engineer melakukan pencarian informasi

berdasarkan buku manual mesin dan *what-if simulation* terhadap perubahan kondisi mesin. Setiap pembacaan data menghasilkan laporan kondisi otomatis yang memuat hasil prediksi, faktor yang mempengaruhi kegagalan, diagnosis AI, rekomendasi pemeriksaan komponen, prosedur penanganan berdasarkan SOP, serta estimasi biaya spare part yang perlu diperiksa atau diganti. Untuk memperoleh data kondisi mesin secara langsung, WoMAI mengintegrasikan perangkat IoT dengan sensor suhu, *photoelectric*, dan sensor suhu non-kontak sebagai masukan prediksi dan pemantauan.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, berikut rumusan masalah dalam WoMAI:

1. Bagaimana mengoptimalkan proses operasional dan menjaga kontinuitas mesin melalui integrasi perangkat *wearable* IoT dengan WoMAI untuk memperoleh data kondisi mesin secara langsung?
2. Bagaimana mengurangi dampak finansial akibat *unplanned downtime* melalui prediksi kegagalan dan *early warning* hingga 10 menit ke depan serta menjelaskan faktor yang mempengaruhi risiko menggunakan *machine learning*, SHAP, dan analisis AI?
3. Bagaimana meningkatkan keselamatan operasional dengan memberikan peringatan terhadap kondisi mesin yang berisiko sehingga tindakan pemeriksaan dapat dilakukan sebelum terjadi gangguan dengan bantuan AI?
4. Bagaimana meningkatkan efektivitas pengambilan keputusan *maintenance* melalui ekstraksi pengetahuan dari buku pedoman dan manual mesin menjadi *knowledge base*, serta penerapan *Agentic AI* pada WoMAI untuk memberikan rekomendasi, *what-if simulation*, dan laporan kondisi beserta informasi komponen yang perlu diperiksa atau diganti?

1.3 Tujuan

Berdasarkan rumusan masalah tersebut, berikut tujuan dari pengembangan WoMAI:

1. Mengoptimalkan proses operasional dan menjaga kontinuitas mesin melalui integrasi perangkat *wearable* IoT dengan WoMAI untuk memperoleh data kondisi mesin secara langsung.
2. Mengurangi dampak finansial akibat *unplanned downtime* melalui deteksi dan prediksi potensi kegagalan mesin secara dini.
3. Meningkatkan keselamatan operasional melalui pemantauan dan peringatan terhadap kondisi mesin yang berisiko.
4. Meningkatkan efektivitas pengambilan keputusan maintenance melalui pemanfaatan pengetahuan teknis dan Agentic AI pada WoMAI untuk membantu *engineer* dalam menentukan tindakan pemeliharaan.

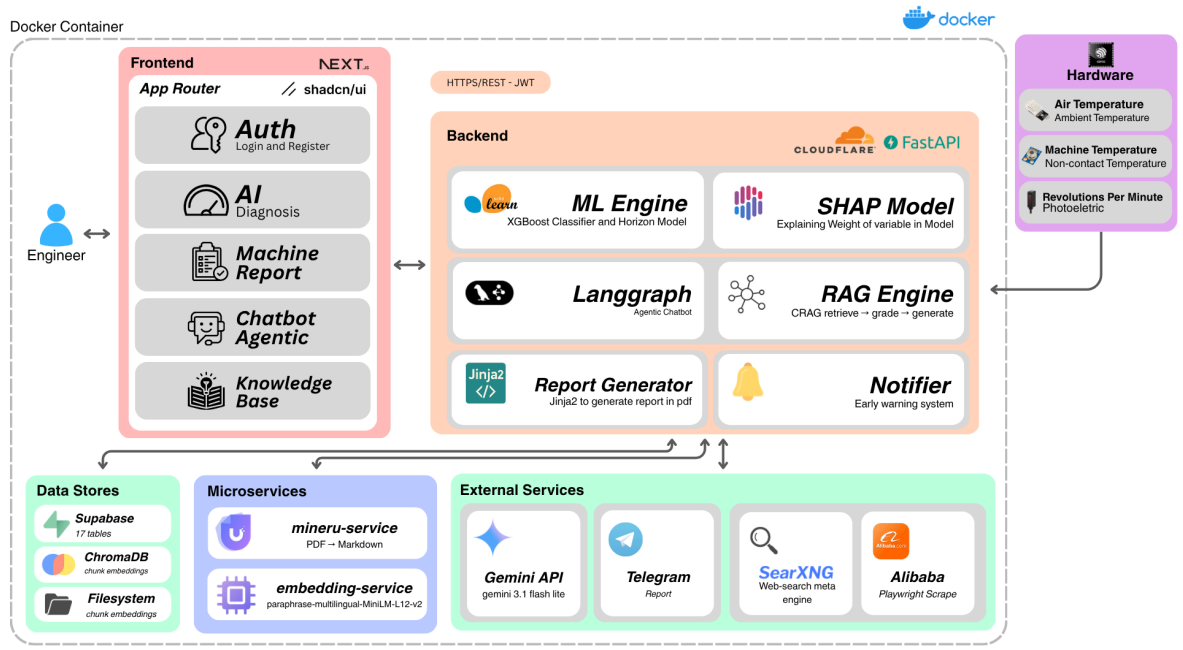
1.4 Manfaat

Pengembangan WoMAI diharapkan memberikan manfaat sebagai berikut:

1. **Manfaat Operasional:** meningkatkan kontinuitas dan keandalan operasional mesin melalui pemantauan kondisi mesin secara langsung sehingga potensi gangguan dapat diketahui lebih awal.
2. **Manfaat Finansial:** mengurangi potensi kerugian akibat *unplanned downtime* melalui deteksi kegagalan secara dini sehingga tindakan pemeliharaan dapat dilakukan sebelum terjadi penghentian proses produksi.
3. **Manfaat Keselamatan:** mendukung keselamatan kerja dengan memberikan peringatan terhadap kondisi mesin yang berisiko sehingga pemeriksaan dan penanganan dapat dilakukan sebelum terjadi gangguan yang berpotensi membahayakan.
4. **Manfaat Efektivitas:** meningkatkan efektivitas pengambilan keputusan *maintenance* dengan menyediakan informasi kondisi mesin, pengetahuan dari dokumen teknis, rekomendasi penanganan, dan bantuan AI dalam satu platform untuk mendukung *engineer*.

II. METODOLOGI

Pengembangan WoMAI mengintegrasikan perangkat IoT, machine learning, LLM, dan RAG berbasis Agentic AI dalam satu arsitektur untuk mendukung pemantauan dan pemeliharaan mesin. Arsitektur ini mencakup hardware, frontend, backend, penyimpanan data, microservices, serta layanan eksternal yang terintegrasi untuk menghasilkan informasi dan rekomendasi maintenance bagi engineer..



Gambar 1. Diagram Arsitektur WoMAI

Arsitektur WoMAI terdiri atas beberapa layanan yang terintegrasi mulai dari akuisisi data, pemrosesan prediksi, pengelolaan pengetahuan, hingga interaksi dengan engineer. Pada

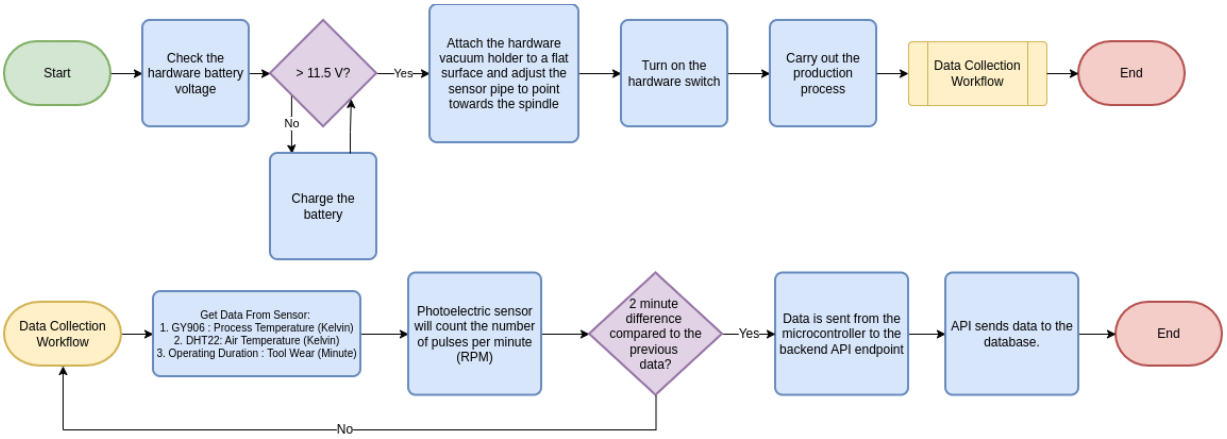
sisi hardware, perangkat IoT menggunakan DHT22 untuk mengukur air temperature, GY-906 untuk mengukur *machine temperature* secara non-kontak, dan sensor *photoelectric* untuk mengukur kecepatan putaran mesin (RPM). Data sensor dikirim melalui API ke *backend* yang di-deploy menggunakan Cloudflare, kemudian diproses oleh FastAPI dan ML *Engine* menggunakan XGBoost *Classifier* dan Horizon Model untuk mendeteksi serta memprediksi potensi kegagalan, sementara SHAP digunakan untuk menjelaskan faktor yang memengaruhi prediksi.

Hasil prediksi digunakan oleh Notifier untuk memberikan *early warning* melalui Telegram. Untuk mendukung diagnosis dan rekomendasi, MinerU Service dan *Embedding Service* mengekstraksi buku manual mesin secara otomatis dan menghasilkan embedding yang disimpan pada ChromaDB sebagai *knowledge base*. RAG *Engine* mengambil informasi relevan dari *knowledge base*, sedangkan LangGraph mengorkestrasi LLM agar dapat menjalankan *Agentic* AI dalam proses analisis dan pemberian respons kepada *engineer*.

Pada sisi *frontend*, Next.js App Router menyediakan fitur AI *Diagnosis*, *Machine Report*, *Chatbot Agentic*, dan *Knowledge Base*. Gemini API digunakan sebagai layanan LLM, sedangkan SearXNG mencari informasi spare part yang berpotensi perlu diperiksa atau diganti dan Alibaba menyediakan informasi harga untuk estimasi anggaran penggantian komponen. Hasil analisis kemudian diproses oleh Report Generator berbasis Jinja2 menjadi laporan kondisi mesin dalam format PDF.

2.1 Alur Pengambilan Data & Integrasi *Hardware*

Pengambilan data dilakukan menggunakan perangkat IoT yang dipasang pada mesin *milling* milik Politeknik Elektronika Negeri Surabaya (PENS) yang digunakan untuk kegiatan praktikum, produksi proyek mahasiswa, dan penelitian. Perangkat IoT dilengkapi GY-906 yang diarahkan ke spindle untuk mengukur *process temperature*, *sensor photoelectric* untuk mengukur *rotational speed* berdasarkan jumlah putaran per menit (RPM), serta DHT22 untuk mengukur *air temperature* di sekitar mesin.



Gambar 2. *Flowchart* Pengambilan Data & Integrasi *Hardware* WoMAI

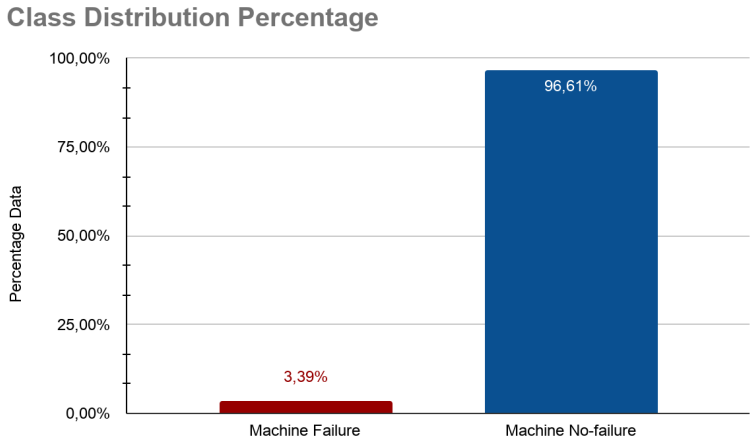
Seperti ditunjukkan pada Gambar 2, pengambilan data diawali dengan pemeriksaan perangkat dan pemasangan IoT pada mesin sebelum proses produksi dimulai. Data kondisi

mesin diambil secara sampling dengan interval 2, 3, dan 5 menit selama lebih dari dua minggu waktu operasional mesin, kemudian dikirim dari mikrokontroler ke *backend* melalui API dan disimpan sebagai log pada *database*. Kondisi *failure* ditentukan ketika proses produksi berhenti karena mesin atau komponennya memerlukan perbaikan, baik minor maupun mayor, seperti *end mill* yang terlepas, terlalu bergoyang, ataupun kendala lainya.

Tabel 1. Analisis Deskriptif Variabel

Analisis	Variabel			
	Air Temperature	***Process Temperature***	***Rotational Speed***	***Tool Wear / Operational Duration***
Mean	300 K	310 K	1538.8 RPM	107.95 Minute
Min	295.3 K	305.7 K	1168 RPM	0 Minute
Max	304.5 K	313.8 K	2886 RPM	253 Minute

Berdasarkan Tabel 1, *air temperature* memiliki variasi yang relatif kecil, sedangkan *process temperature* berada pada tingkat yang lebih tinggi karena merepresentasikan panas yang dihasilkan selama proses pemesinan. *Rotational speed* memiliki variasi yang lebih besar karena mengikuti kondisi operasi mesin, sementara *tool wear/operational duration* menunjukkan perubahan berdasarkan lama penggunaan mesin. Variasi tersebut memberikan gambaran kondisi operasional yang dapat digunakan untuk mengidentifikasi perubahan perilaku mesin dan mendukung proses prediksi *failure*.



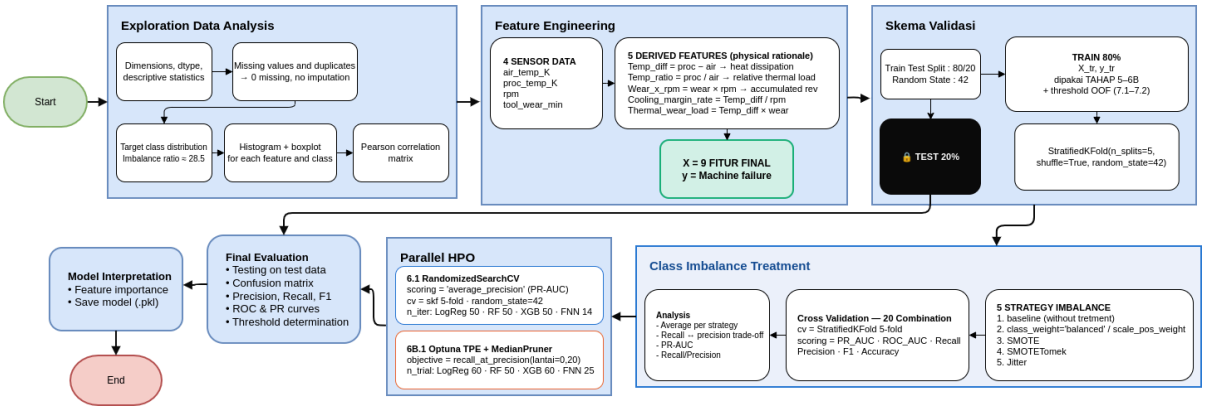
Gambar 3. Grafik Batang Distribusi Kelas

Berdasarkan distribusi *class* pada Gambar 3, sebanyak 96,61% data berada pada kelas *non-failure*, sedangkan 3,39% data berada pada kelas *failure*. Distribusi tersebut menunjukkan bahwa data memiliki ketidakseimbangan kelas (*class imbalance*), sehingga kondisi ini perlu diperhatikan pada tahap pengembangan dan evaluasi model prediksi kegagalan mesin.

2.2 Alur Pengembangan Model AI

2.2.1 Model Klasifikasi Kegagalan Mesin

Pengembangan model klasifikasi kegagalan mesin menggunakan algoritma *XGBoost* diawali dengan *exploratory data analysis* untuk memeriksa dimensi, tipe data, missing value, duplikasi, serta distribusi kelas, yang menunjukkan rasio ketidakseimbangan (imbalance ratio) sebesar 28,5 antara kelas *non-failure* dan *failure*. Empat fitur sensor mentah (*air temperature*, *process temperature*, *rotational speed*, *tool wear*) kemudian diperkaya melalui feature engineering menjadi lima fitur turunan berdasarkan rasional fisik, yaitu selisih suhu, rasio suhu, interaksi keausan-kecepatan, laju margin pendinginan, dan beban keausan termal, sehingga total sembilan fitur final digunakan sebagai input model.



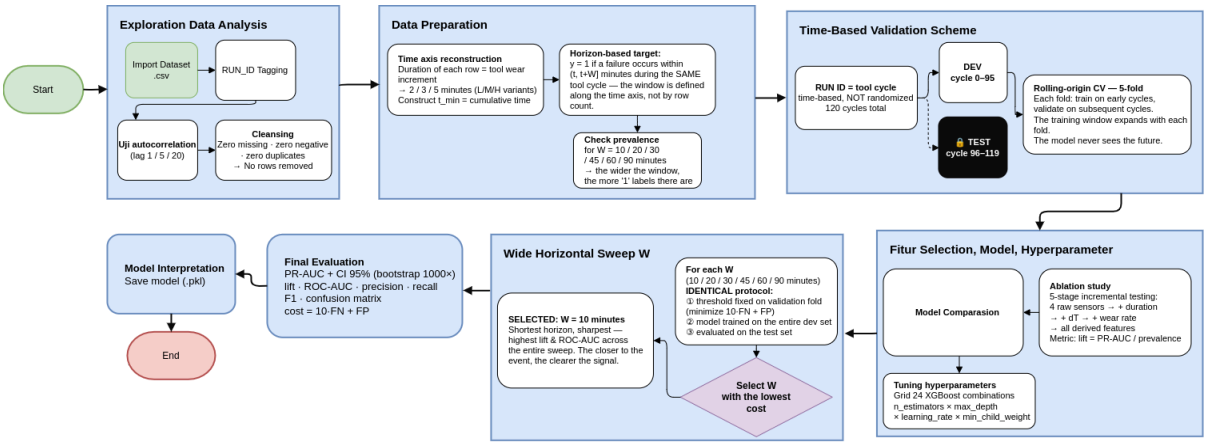
Gambar 4. Alur Pengembangan Model Klasifikasi Kegagalan Mesin

Seperti ditunjukkan pada Gambar 4, data dibagi dengan skema *train-test split* 80:20 menggunakan *StratifiedKFold* lima lipatan pada data latih untuk menjaga proporsi kelas, sementara data uji (20%) disisihkan sepenuhnya hingga tahap evaluasi akhir. Lima strategi penanganan ketidakseimbangan kelas, yaitu baseline tanpa perlakuan, pembobotan kelas (*class_weight/scale_pos_weight*), *SMOTE*, *SMOTETomek*, dan *jitter*, dibandingkan menggunakan cross-validation lima lipatan dengan metrik *PR-AUC*, *ROC-AUC*, *recall*, *precision*, dan *F1*, sebelum dilakukan pencarian hyperparameter secara paralel melalui *Optuna TPE* dengan *MedianPruner*, lalu dievaluasi final pada data uji menggunakan confusion matrix, kurva ROC dan PR, serta penentuan threshold optimal.

2.2.2 Model Prediksi Kegagalan Mesin

Sebagaimana ditunjukkan pada Gambar 5, data diperiksa dulu sebelum model dibuat, keterurutan baris diuji karena data berurutan tidak boleh diacak model akan belajar dari kejadian yang sebenarnya terjadi belakangan, waktu disusun ulang dari keausan pahat yang naik lalu kembali ke nol setiap penggantian sehingga *horizon* bisa ditetapkan dalam menit, dan data dipotong di batas masa pakai pahat agar baris-baris yang sangat mirip tidak terbelah antara data latih dan data uji. *Accuracy* sengaja tidak dipakai karena kerusakan hanya sekitar 3% dari seluruh baris, sehingga model yang menjawab "aman" untuk semua baris otomatis benar 97% tanpa menangkap satu pun kerusakan. Sebagai gantinya dipakai lift dan cost, dengan aturan satu kerusakan terlewat setara sepuluh alarm palsu. Model disusun lewat percobaan bertingkat feature tambahan, lima algoritma berbeda, dan sapuan seluruh

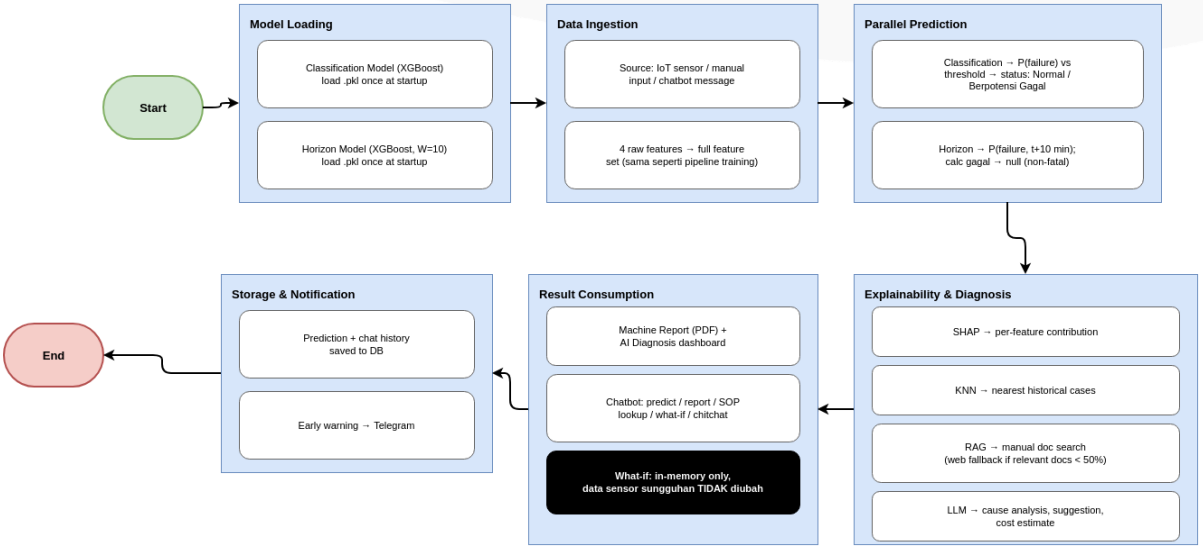
kombinasi setelan yang menimbang bukan hanya skor tapi juga seberapa goyang skor itu kalau potongan data ujinya diganti, dengan aturan yang dikunci sebelum hasil dilihat. Di antara pilihan setara, ambil yang paling sederhana. Beberapa lebar horizon lalu dicoba untuk melihat seberapa jauh ke depan prediksi masih berguna, dan model dibandingkan dengan tiga kebijakan tanpa model ambang keausan sederhana, selalu alarm, dan tak pernah alarm sebab pabrik butuh keputusan termurah, bukan machine learning; kalau aturan satu baris sama baiknya, model tidak layak dipakai berapapun skornya. Seluruh pemilihan ini memakai data latih saja, sementara data uji disegel dan baru dibuka satu kali di akhir setelah batas alarm dikunci.



Gambar 5. Alur Pengembangan Model Horizon Prediksi Kegagalan Mesin

2.3 Alur Integrasi Model AI

Setelah proses pengembangan selesai, *Classification Model* dan *Horizon Model* yang telah disimpan dalam format .pkl (lihat Gambar 4 dan Gambar 5) dimuat ke dalam layanan backend WoMAI satu kali saat sistem berjalan. Setiap kali data sensor terbaru diterima, baik dari perangkat IoT, input manual, maupun percakapan dengan chatbot, data mentah diolah menjadi fitur lengkap sebelum kedua model dijalankan secara paralel, model klasifikasi menentukan status mesin saat ini sementara *Horizon* Model memperkirakan probabilitas kegagalan dalam 10 menit ke depan.



Gambar 6. Alur Integrasi Model AI

Sebagaimana ditunjukkan pada Gambar 6, hasil kedua model dijelaskan lebih lanjut melalui SHAP dan KNN, dilengkapi pencarian dokumen manual servis oleh *RAG Engine*, dengan *fallback* ke pencarian *web* apabila dokumen relevan kurang dari separuh, sebelum *LLM* menyusun *cause analysis*, saran perbaikan, dan estimasi harga komponen. Seluruh hasil ini dikonsumsi secara konsisten oleh *Machine Report*, *AI Diagnosis*, dan *Chatbot*, termasuk simulasi bagaimana-jika yang dijalankan in-memory tanpa mengubah data sensor sungguhan, lalu disimpan sebagai riwayat dan diteruskan sebagai early warning melalui Telegram.

III. HASIL DAN PEMBAHASAN

3.1 Evaluasi Model AI

3.1.1 Model Klasifikasi Kegagalan Mesin

Tabel 2. Hasil model RandomSearchCV

Model	PR-AUC CV	PR-AUC test	Recall	Precision	F1
XGBoost	**0,6355**	**0,6857**	**0,5577**	**0,8286**	**0,6667**
RandomForest	0,6254	0,6475	0,5577	0,9062	0,6905
FNN	0,5030	0,6147	0,5192	0,6750	0,5870
LogisticRegression	0,2749	0,3900	0,5192	0,4091	0,4576

Tabel 3. Hasil model optuna TPE

Model	PR-AUC CV	PR-AUC test	Recall	Precision	F1
XGBoost	**0,6295**	**0,6913**	**0,5577**	**0,8788**	**0,6824**
RandomForest	0,6124	0,6392	0,4808	1,0000	0,6494
FNN	0,5339	0,6487	0,5385	0,6829	0,6022
LogisticRegression	0,2286	0,3126	0,5769	0,3000	0,3947

Tabel 2 (*RandomizedSearchCV*, objektif *PR-AUC*) dan Tabel 3 (*Optuna TPE*, objektif *recall* dengan *precision floor* 20%) membandingkan empat model yang sama, sehingga perbedaan objektif itu sendiri yang menjelaskan pola hasilnya dimana *Optuna* menurunkan *PR-AUC CV* sedikit sambil menggeser operating point ke arah recall. Perbaikannya tidak seragam *PR-AUC* test naik pada *XGBoost* dan *FNN*, tapi turun pada *RandomForest* dan LogisticRegression jadi Optuna bukan jaminan perbaikan. PR-AUC dipakai sebagai metrik utama karena kelas gagal hanya 2,63%, rasio di mana accuracy dimaksimalkan dengan menebak "normal" terus. *XGBoost* menang di kedua tabel, tapi keunggulan versi Optuna (*PR-AUC test* 0,6913 vs 0,6857; *F1* 0,6824 vs 0,6667) jauh lebih kecil daripada simpangan baku lima seed (±0,055), sehingga keduanya secara statistik setara dan manfaat *Optuna* hanya nyata saat recall memang yang dikejar (43 dari 52 kegagalan tertangkap vs 41). Model yang dikirim adalah *XGBoost* tanpa *Optuna* pada threshold 0,2544 karena kriterianya expected cost minimum pada rasio 10:1, bukan akurasi dan dengan hanya 52 kegagalan di test set, bergesernya satu-dua kasus sudah mengubah recall ~1,9 poin persen.

3.1.2 Model Prediksi Kegagalan Mesin

Tabel 4. Ringkasan hasil prediksi kegagalan

Tahap	Jumlah dicoba	Yang terpilih	Interpretasi
Feature	5 kelompok	4 sensor mentah	selisih antar kelompok lebih kecil dari goyangannya, feature tambahan tidak terbukti membantu
Algoritma	5 algoritma	XGBoost	tiga teratas setara, dipilih atas alasan praktis
Setelan model	24 kombinasi	300 tree, depth 3	setelan paling sederhana yang menang, model rumit tidak menemukan pola baru
Lebar horizon	5 horizon	10 menit	horizon pendek paling tajam, horizon lebar berubah jadi sirene
Model final	-	cost 607	kalah dari wear rule (468)

Tabel 5. Perbandingan model

Model	Cost false	Selisih terhadap XGBoost
Wear rule (berdasarkan Tool Wear Cycle)	**468**	139 **lebih baik** dari model
Model XGBoost	**607**	-
Tak pernah alarm	610	3
Selalu alarm	1.811	1.204 lebih buruk

Berdasarkan tabel 2, keempat tahap menunjuk ke kesimpulan yang sama yaitu sinyal dalam data memang tipis. Penyebabnya terlihat sejak pemeriksaan awal, kecepatan putar mesin nilainya acak (*autocorrelation* +0,008), sehingga kerusakan yang dipicu variabel ini tidak punya tanda awal apa pun untuk dipelajari. Karena itu feature tambahan tidak membantu, lima algoritma berbeda hasilnya sama, dan model yang lebih rumit tidak lebih baik. Keterbatasannya ada pada data, bukan pada pemilihan model.

Berdasarkan tabel 3, model prediksi failure terbaik ada pada penggunaan algoritma XGBoost. Meskipun secara *cost false* (biaya kesalahan alarm) lebih besar 139 terhadap *wear rule*, XGBoost bersifat non deterministik, sehingga tuning pada dataset baru pada production mendapatkan hasil yang baik. Hal ini mempertimbangkan bahwasanya dataset pada level production akan memiliki *data drift.*

3.1.3 Cause Analysis LLM

Cause Analysis LLM mematuhi prompt engineering dengan baik. Kualitas jawabannya diukur menggunakan metrik *Faithfulness* dari *RAGAS*, dijalankan satu kali secara sinkron di dalam pipeline laporan. Hasil pengukurannya disajikan pada Tabel 2. Hasil Metrik *Faithfulness*, dengan skor yang diperoleh sebesar 0,5294 atau sekitar 53 %. Angka tersebut menunjukkan bahwa sekitar separuh klaim pada jawaban akar masalah tidak dapat ditelusuri ke konteks yang benar-benar terambil, sejalan dengan temuan sitasi yang hilang maupun berpola fabrikasi pada ringkasan yang diturunkan darinya.

3.1.4 Suggestion for Improvement

Fitur *Suggestions for Improvement* di panel *AI Explanation* sudah berjalan dengan pemisahan tugas yang jelas, angka rekomendasi dan arah penyesuaiannya (naik/turun) sepenuhnya berasal dari perhitungan worst-case delta berbasis *KNN* yang deterministik, sementara *LLM* (*Gemini*) hanya menulis satu kalimat penjelasan dalam bahasa natural, tanpa menyebut angka, dan memakai istilah umum dari mapping yang di-hardcode (*tool_wear_min → "machine operating time", rpm → "speed"*, dst.), dengan prompt yang melarang kata-kata ragu-ragu dan memaksa kalimat langsung, jadi hasilnya tetap akurat karena datang dari *ML* tapi nyaman dibaca karena dirangkai *LLM*. Untuk menguji konsistensi dari hasil suggestion, penulis membaca dari semua percobaan yang telah terjadi, dimana total terdapat 435 percobaan.. Hasil ditunjukan pada tabel 3 Uji Konsisten Suggestion. Disimpulkan bahwa fitur *Suggestion for Improvement* sangat konsisten, hingga hasil dapat dipercaya sebagai rekomendasi pengembangan mesin milling CNC.

Tabel 6. Uji Konsistensi Suggestion

Kriteria	Hasil	Skor
Memunculkan nilai numerik secara langsung	0/435 percobaan	100%
hedging (kata ragu-ragu)	0 kemunculan *hedging*	100%
Menggunakan istilah general	0 kesalahan istilah	100%
Arah (increase/decrease) konsisten dengan delta KNN	435/435 match dengan target value vs current value	100%

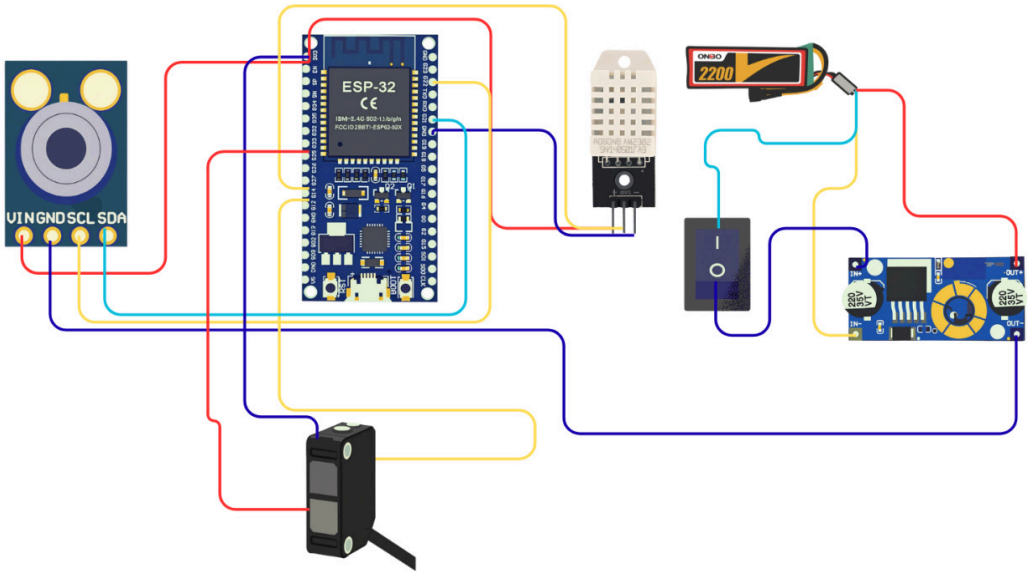
3.2 Sistem *Website*

Sistem *website* WoMAI dibangun menggunakan Next.js App Router sebagai antarmuka utama bagi engineer untuk memantau kondisi mesin, memperoleh hasil analisis, mengakses dokumentasi teknis, serta berinteraksi dengan *Machine Copilot*. Empat fitur utama yang disediakan meliputi *AI Diagnosis*, *Machine Report*, *Knowledge Base*, dan *Machine Copilot*, yang terintegrasi dengan komponen AI pada *backend*. AI Diagnosis menampilkan hasil prediksi kondisi mesin beserta faktor yang memengaruhi hasil prediksi melalui model klasifikasi, Horizon Model, dan SHAP, sedangkan Machine Report menyajikan hasil analisis tersebut dalam bentuk laporan kondisi mesin yang lebih terstruktur.

Fitur Knowledge Base menyediakan akses terhadap pengetahuan teknis yang berasal dari buku pedoman dan manual mesin yang telah diekstraksi serta diolah menjadi basis pengetahuan. Pengetahuan tersebut digunakan oleh RAG Engine untuk mengambil informasi yang relevan ketika dibutuhkan dalam proses diagnosis maupun konsultasi. Sementara itu, Machine Copilot memanfaatkan Agentic AI untuk membantu engineer melakukan konsultasi mengenai kondisi mesin, mencari informasi teknis, dan melakukan what-if simulation berdasarkan perubahan parameter kondisi mesin. Dengan demikian, engineer tidak hanya memperoleh hasil prediksi, tetapi juga dapat memahami kondisi mesin dan memperoleh informasi yang relevan untuk mendukung keputusan maintenance.

Machine Report juga berfungsi sebagai dokumentasi hasil pemantauan dengan menggabungkan informasi dari prediksi kondisi, faktor yang memengaruhi kegagalan, diagnosis, rekomendasi pemeriksaan, serta informasi penanganan yang relevan dari knowledge base. Kelima tampilan pada Gambar 17 sampai Gambar 21 (Lampiran) memperlihatkan implementasi antarmuka dan hubungan antarfitur tersebut. Seluruh informasi yang ditampilkan, mulai dari status kegagalan, isi laporan, hingga respons Machine Copilot, menggunakan sumber prediksi dan knowledge base yang terintegrasi sehingga informasi yang diterima engineer tetap konsisten di berbagai fitur WoMAI.

3.3 Sistem *Hardware* IoT



Gambar 7. Wiring Sistem *Hardware*

Berdasarkan diagram elektrik pada Gambar 7, sistem IoT menggunakan ESP32 sebagai pengendali utama yang mengatur proses pembacaan sensor dan komunikasi data. Tiga sensor digunakan untuk memperoleh parameter kondisi mesin, yaitu DHT22 untuk mengukur air temperature dan kelembapan lingkungan, GY-906 (MLX90614) untuk mengukur process temperature secara non-kontak, serta sensor photoelectric inframerah untuk mendeteksi putaran spindle berdasarkan pulsa yang dihasilkan. Masing-masing sensor dihubungkan ke ESP32 melalui jalur komunikasi dan catu daya sesuai kebutuhan, dengan seluruh komponen menggunakan common ground agar memiliki referensi tegangan yang sama dan pembacaan sensor dapat berlangsung secara stabil.

Sumber daya sistem berasal dari baterai LiPo 12 V sehingga perangkat dapat digunakan secara portable pada mesin milling. Karena ESP32 dan sensor membutuhkan tegangan yang lebih rendah, tegangan baterai diturunkan menggunakan modul step-down XL4005 menjadi tegangan keluaran yang sesuai untuk rangkaian elektronik. Aliran daya dikendalikan menggunakan saklar yang berfungsi sebagai pemutus dan penyambung sumber listrik utama, sehingga perangkat dapat diaktifkan atau dimatikan tanpa perlu melepas baterai. Konfigurasi ini memungkinkan seluruh sensor dan ESP32 memperoleh daya dari satu sumber yang sama tanpa bergantung pada catu daya eksternal.



(a) **(b)**

Gambar 8. Perangkat *Hardware*

Pada implementasinya, GY-906 ditempatkan pada bagian perangkat IoT yang diarahkan ke area spindle mesin untuk memperoleh temperatur permukaan secara non-kontak, sehingga sensor tidak perlu bersentuhan langsung dengan komponen yang berputar. Sensor photoelectric ditempatkan menghadap bagian spindle atau objek referensi putaran untuk mendeteksi setiap pulsa akibat pergerakan dan selanjutnya digunakan untuk menghitung rotational speed (RPM). Sementara itu, DHT22 digunakan untuk merekam kondisi temperatur udara di sekitar mesin sebagai representasi kondisi lingkungan selama proses pemesinan. Seperti ditunjukkan pada dokumentasi perangkat, rangkaian sensor dan catu daya ditempatkan dalam casing untuk melindungi komponen elektronik serta memudahkan perangkat dibawa dan dipasang pada mesin. Dengan konfigurasi tersebut, ESP32 berfungsi sebagai pusat akuisisi data yang membaca seluruh parameter sensor secara berkala sebelum data kondisi mesin diteruskan ke sistem WoMAI. Gambar 12 menunjukkan hubungan kelistrikan antar-komponen, sedangkan dokumentasi perangkat memperlihatkan bentuk fisik wearable IoT yang digunakan dalam proses pengambilan data.

KESIMPULAN & RENCANA PENGEMBANGAN

4.1 Rencana Pengembangan

WoMAI dirancang sebagai platform wearable end-to-end yang dapat diterapkan pada berbagai jenis mesin milling, sehingga pengembangan selanjutnya diarahkan pada tiga arah utama. Pertama, otomasi machine learning workflow melalui orkestrasi berbasis Apache Airflow untuk menjalankan validasi data, retraining, evaluasi, dan pembaruan model secara otomatis setiap kali mesin baru ditambahkan atau data operasional bertambah, sehingga skalabilitas sistem tidak lagi bergantung pada intervensi manual. Kedua, peningkatan Cause Analysis dari arsitektur CRAG saat ini menuju Agentic AI yang lebih matang, dengan prioritas pada akurasi query RAG, validasi sitasi, konsolidasi mapping istilah teknis, dan pengecekan kualitas otomatis terhadap keluaran LLM. Ketiga, pengembangan sistem multi-user dengan hak akses berjenjang bagi *engineer*, operator, dan supervisor, agar WoMAI dapat diadopsi sebagai platform kolaboratif di lingkungan pabrik yang sesungguhnya.

4.2 Kesimpulan

Evaluasi model klasifikasi kegagalan mesin menunjukkan XGBoost sebagai model terbaik pada kedua skema tuning, dengan PR-AUC test 0,6857 (RandomizedSearchCV) dan 0,6913 (Optuna TPE), namun selisih tersebut jauh lebih kecil daripada simpangan baku lima seed (±0,055) sehingga keduanya secara statistik setara. PR-AUC dipilih sebagai metrik utama karena kelas gagal hanya 2,63%, kondisi di mana accuracy dapat dimaksimalkan hanya dengan menebak kelas "normal" terus-menerus. Model yang akhirnya di-deploy adalah XGBoost tanpa Optuna pada threshold 0,2544 karena kriteria pemilihannya adalah expected cost minimum pada rasio 10:1, bukan akurasi. Pada sisi prediksi, empat tahap eksperimen (feature, algoritma, hyperparameter, dan lebar horizon) menunjuk kesimpulan yang sama, yaitu sinyal dalam data memang tipis: rotational speed bersifat acak (autocorrelation +0,008) sehingga kegagalan yang dipicu variabel ini tidak meninggalkan tanda awal yang bisa dipelajari. Konsekuensinya, Horizon Model XGBoost (cost 607) masih kalah dari wear rule sederhana (cost 468), sehingga keterbatasan terletak pada data, bukan pada pemilihan model.

Komponen berbasis LLM memperlihatkan hasil yang terbelah antara dua fitur yang arsitekturnya berbeda. Cause Analysis LLM memperoleh skor Faithfulness RAGAS sebesar 0,5294, yang berarti sekitar separuh klaim pada jawaban akar masalah tidak dapat ditelusuri ke konteks yang benar-benar terambil dan sejalan dengan temuan sitasi hilang maupun berpola fabrikasi. Sebaliknya, fitur Suggestion for Improvement mencapai konsistensi 100% pada seluruh 435 percobaan untuk keempat kriteria uji, termasuk kesesuaian arah increase/decrease terhadap delta KNN. Perbedaan ini berasal dari pembagian tugas yang tegas: seluruh angka dan arah rekomendasi dihasilkan perhitungan worst-case delta berbasis KNN yang deterministik, sementara LLM hanya merangkai satu kalimat penjelasan tanpa menyebut angka. Pola ini menegaskan bahwa keandalan keluaran LLM meningkat ketika perannya dibatasi pada verbalisasi, bukan pada penarikan kesimpulan.

Secara keseluruhan, WoMAI berhasil mengintegrasikan perangkat IoT berbasis ESP32 dengan tiga sensor, model machine learning, dan Agentic AI berbasis LLM ke dalam satu sistem pemeliharaan prediktif yang berjalan real-time. Sistem website Next.js menyalurkan seluruh keputusan dari model klasifikasi, Horizon Model, SHAP, dan RAG Engine yang sama ke empat fitur utama, sehingga engineer memperoleh informasi yang konsisten di *AI Diagnosis, Machine Report, Knowledge Base*, maupun *Machine Copilot*. Dengan demikian rumusan masalah dan tujuan pada Bab 1 telah terjawab, meskipun dua catatan penting tetap melekat pada hasil ini. Pertama, performa Horizon Model masih dibatasi kualitas sinyal dataset, sehingga XGBoost dipertahankan karena sifatnya yang non-deterministik memungkinkan tuning ulang saat menghadapi data drift pada level production. Kedua, akurasi retrieval pada Cause Analysis LLM masih perlu diperbaiki, sehingga validasi lanjutan pada data produksi nyata tetap diperlukan sebelum penerapan skala penuh.

DAFTAR PUSTAKA

Aulia, I.R., Hermawan, A. and Avianto, D. (2025) 'Pendekatan Hybrid: Naïve Bayes dan Decision Tree untuk Prediksi Kerusakan Mesin pada Industri Manufaktur PT X', *IJAI (Indonesian Journal of Applied Informatics)*, 9(2).

Eurostat (2025) 'Accidents at work – statistics on causes and circumstances', Statistics Explained. Available at: https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Accidents_at_work_-_statistics_on_causes_and_circumstances (Accessed: 18 August 2026).

Hilman, A., Guntara, Y. and Sugiyanto (2023) 'Implementation of Lean to Reduce Unplanned Downtime Due to Material Shortage at PT. NPI Kalimantan Barat', HUMANIST (Humanities, Management and Science Proceedings), 4(1), pp. 276–287.

Mali, R.A., Gupta, T.V.K. and Ramkumar, J. (2021) 'A comprehensive review of free-form surface milling–Advances over a decade', Journal of Manufacturing Processes, 62, pp. 132–167.

Mustofa, R., Yudha, V. and Faizin, M. (2025) 'Analisis Tingkat Efisiensi Mesin CNC Milling Berdasarkan Nilai Overall Equipment Effectiveness (OEE) dan Six Big Losses', ROTASI, 27(2), pp. 64–70.

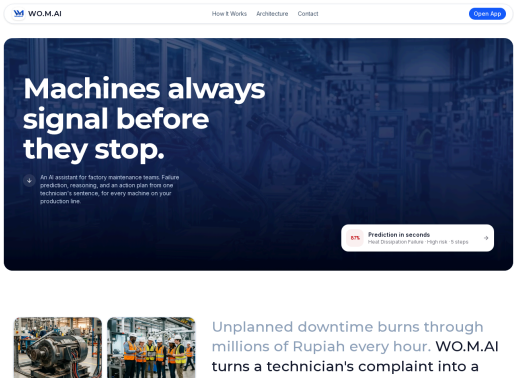
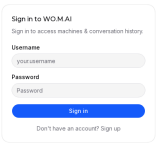
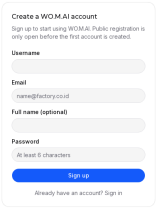
Siemens AG (2024) The True Cost of Downtime 2024: How much do leading manufacturers lose through inefficient maintenance? Erlangen: Siemens AG. Available at: https://assets.new.siemens.com/siemens/assets/api/uuid:1b43afb5-2d07-47f7-9eb7-893fe7d0bc59/tcod-2024_original.pdf (Accessed: 18 August 2026).

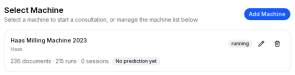
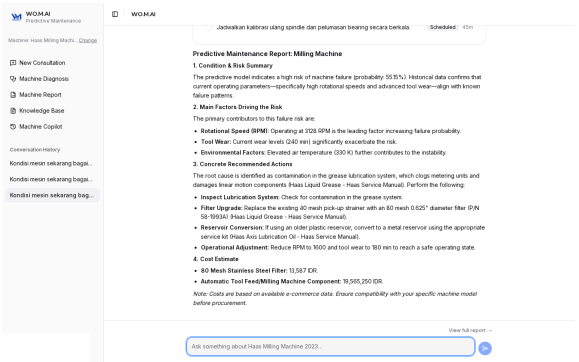
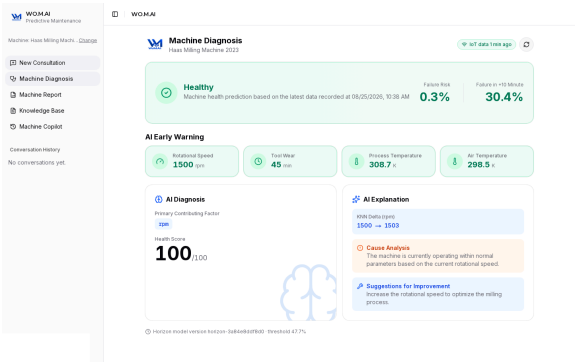
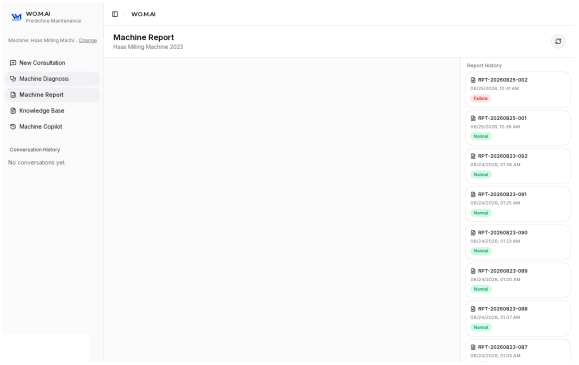
Wijayanto, H.L., Setiawan, A.T., Putra, E.A.P., Alfafa, A.M. and Saputra, A.T. (2025) 'Peningkatan Pengetahuan Operasional Mesin Frais Bagi Karyawan Di Kawasan Industri Logam Morowali', JOONG-KI: Jurnal Pengabdian Masyarakat, 5(1).

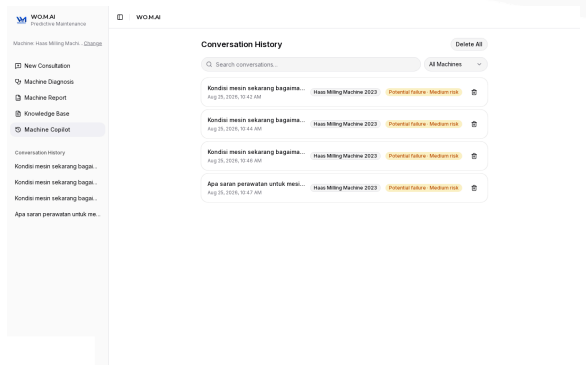
LAMPIRAN

Lampiran 1. Tampilan Website WoMAI

Tabel 7. Keterangan Prototipe Tampilan Aplikasi

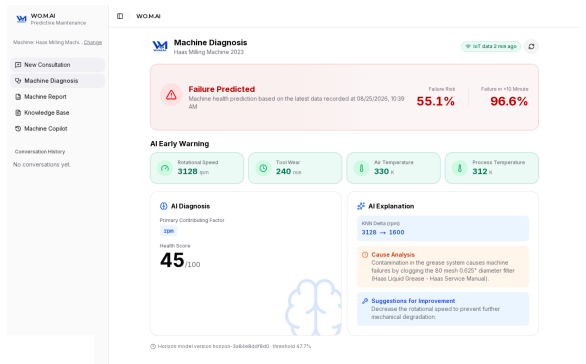
Tampilan	Deskripsi
 **Gambar 9.** Landing page WoMAI	Landing page WoMAI yang memperkenalkan produk kepada pengunjung sebelum masuk ke sistem.
 **Gambar 10.** Login page	Halaman login untuk autentikasi engineer sebelum mengakses dashboard WoMAI.
 **Gambar 11.** Register page	Halaman pendaftaran akun baru bagi pengguna WoMAI.

 **Gambar 12.** Machine list page	Daftar mesin terdaftar, tempat engineer memilih mesin aktif sebelum mengakses fitur lainnya.
 **Gambar 13.** Machine Copilot WoMAI	Tampilan awal Machine Copilot sebelum percakapan dimulai.
 **Gambar 14.** AI Diagnosis (Healthy)	AI Diagnosis pada kondisi mesin Normal, sebagai pembanding kondisi Berpotensi Gagal pada Gambar 7.
 **Gambar 15.** Report Page	Daftar riwayat Machine Report yang tersimpan untuk suatu mesin.



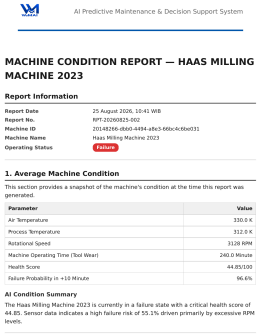
Gambar 16. History Page

Riwayat percakapan (Conversation History) dengan Machine Copilot.



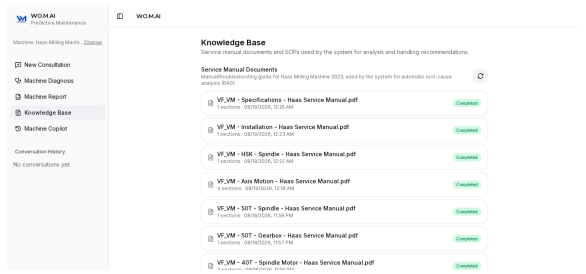
Gambar 17. AI Diagnosis (Failure)

AI Diagnosis pada kondisi mesin Berpotensi Gagal, menampilkan failure risk, probabilitas kegagalan 10 menit ke depan, SHAP, cause analysis, dan saran perbaikan.



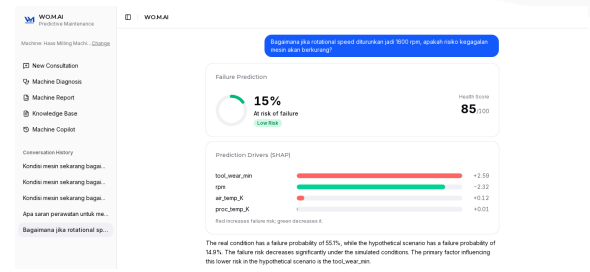
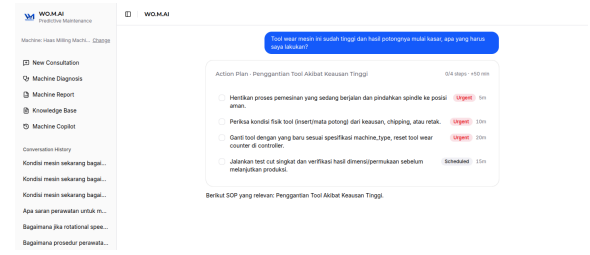
Gambar 18. Report Document

Machine Report yang dihasilkan otomatis oleh Report Generator setiap kali data sensor baru diterima, memuat ringkasan kondisi, faktor risiko utama, dan rekomendasi tindakan.



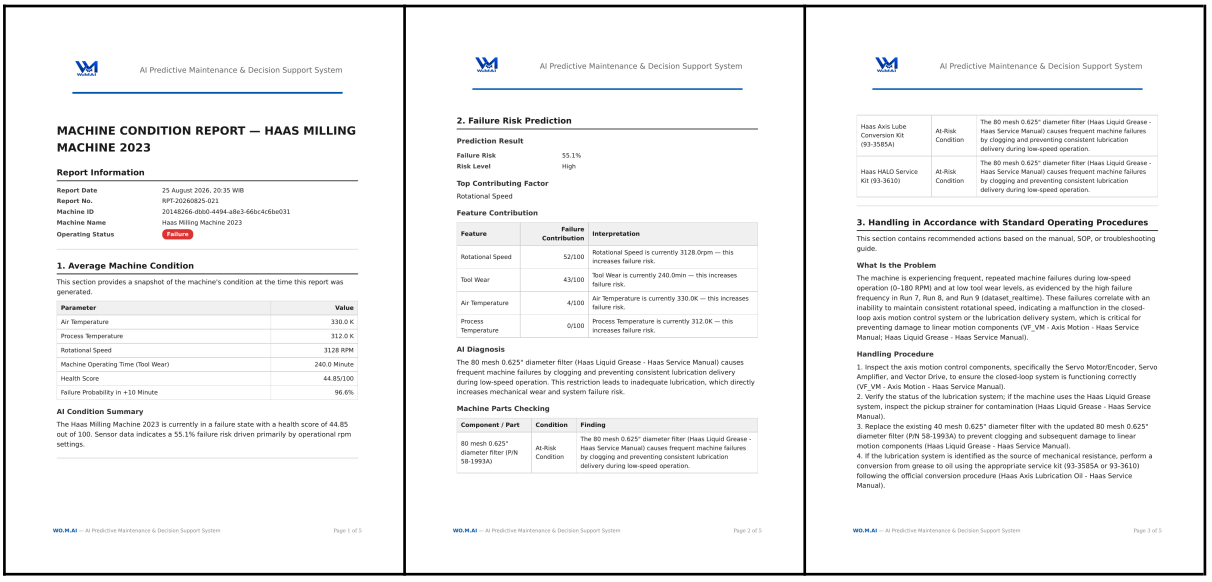
Gambar 19. Knowledge Base Page

Knowledge Base berisi dokumen manual servis mesin yang diekstraksi otomatis dan diindeks pada ChromaDB sebagai rujukan RAG Engine.

 **Gambar 20.** What-if Chatbot	Machine Chatbot Copilot menjalankan what-if simulation secara in-memory ketika engineer menanyakan dampak perubahan suatu parameter sensor.
 **Gambar 21.** SOP Chatbot	Machine Chatbot Copilot mencocokkan gejala yang disampaikan engineer dengan SOP penanganan yang relevan dengan action plan, prioritas, dan estimasi waktu.

Lampiran 2. Full PDF Report

Berikut Machine Condition Report lengkap (5 halaman) yang dihasilkan otomatis oleh sistem WoMAI untuk salah satu kondisi mesin Berpotensi Gagal, mencakup ringkasan kondisi, prediksi risiko, diagnosis AI, prosedur penanganan, estimasi biaya komponen, log kondisi, dan rekomendasi tindakan.



AI Predictive Maintenance & Decision Support System

MACHINE CONDITION REPORT — HAAS MILLING MACHINE 2023

Report Information

Report Date	25 August 2026, 20:35 WIB
Report No.	RPT-20260825-021
Machine ID	20148266-dbb0-4494-a8e3-66bc4c6be031
Machine Name	Haas Milling Machine 2023
Operating Status	Failure

1. Average Machine Condition

This section provides a snapshot of the machine's condition at the time this report was generated.

Parameter	Value
Air Temperature	330.0 K
Process Temperature	312.0 K
Rotational Speed	3128 RPM
Machine Operating Time (Tool Wear)	240.0 Minute
Health Score	44.85/100
Failure Probability in +10 Minute	96.6%

AI Condition Summary

The Haas Milling Machine 2023 is currently in a failure state with a health score of 44.85 out of 100. Sensor data indicates a 55.1% failure risk driven primarily by operational rpm settings.

WO.M.AI — AI Predictive Maintenance & Decision Support System Page 1 of 5

AI Predictive Maintenance & Decision Support System

2. Failure Risk Prediction

Prediction Result

Failure Risk 55.1%
Risk Level High

Top Contributing Factor

Rotational Speed

Feature Contribution

Feature	Failure Contribution	Interpretation
Rotational Speed	52/100	Rotational Speed is currently 3128.0rpm — this increases failure risk.
Tool Wear	43/100	Tool Wear is currently 240.0min — this increases failure risk.
Air Temperature	4/100	Air Temperature is currently 330.0K — this increases failure risk.
Process Temperature	0/100	Process Temperature is currently 312.0K — this increases failure risk.

AI Diagnosis

The 80 mesh 0.625" diameter filter (Haas Liquid Grease - Haas Service Manual) causes frequent machine failures by clogging and preventing consistent lubrication delivery during low-speed operation. This restriction leads to inadequate lubrication, which directly increases mechanical wear and system failure risk.

Machine Parts Checking

Component / Part	Condition	Finding
80 mesh 0.625" diameter filter (P/N 58-1993A)	At-Risk Condition	The 80 mesh 0.625" diameter filter (Haas Liquid Grease - Haas Service Manual) causes frequent machine failures by clogging and preventing consistent lubrication delivery during low-speed operation.

WO.M.AI — AI Predictive Maintenance & Decision Support System Page 2 of 5

AI Predictive Maintenance & Decision Support System

Haas Axis Lube Conversion Kit (93-3585A)	At-Risk Condition	The 80 mesh 0.625" diameter filter (Haas Liquid Grease - Haas Service Manual) causes frequent machine failures by clogging and preventing consistent lubrication delivery during low-speed operation.
Haas HALO Service Kit (93-3610)	At-Risk Condition	The 80 mesh 0.625" diameter filter (Haas Liquid Grease - Haas Service Manual) causes frequent machine failures by clogging and preventing consistent lubrication delivery during low-speed operation.

3. Handling in Accordance with Standard Operating Procedures

This section contains recommended actions based on the manual, SOP, or troubleshooting guide.

What Is the Problem

The machine is experiencing frequent, repeated machine failures during low-speed operation (0-180 RPM) and at low tool wear levels, as evidenced by the high failure frequency in Run 7, Run 8, and Run 9 (dataset_realtime). These failures correlate with an inability to maintain consistent rotational speed, indicating a malfunction in the closed-loop axis motion control system or the lubrication delivery system, which is critical for preventing damage to linear motion components (VF_VM - Axis Motion - Haas Service Manual; Haas Liquid Grease - Haas Service Manual).

Handling Procedure

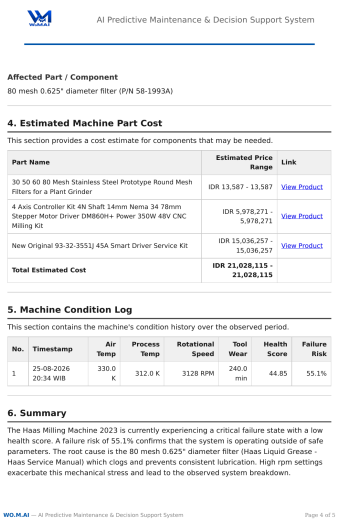
1. Inspect the axis motion control components, specifically the Servo Motor/Encoder, Servo Amplifier, and Vector Drive, to ensure the closed-loop system is functioning correctly (VF_VM - Axis Motion - Haas Service Manual).
2. Verify the status of the lubrication system; if the machine uses the Haas Liquid Grease system, inspect the pickup strainer for contamination (Haas Liquid Grease - Haas Service Manual).
3. Replace the existing 40 mesh 0.625" diameter filter with the updated 80 mesh 0.625" diameter filter (P/N 58-1993A) to prevent clogging and subsequent damage to linear motion components (Haas Liquid Grease - Haas Service Manual).
4. If the lubrication system is identified as the source of mechanical resistance, perform a conversion from grease to oil using the appropriate service kit (93-3585A or 93-3610) following the official conversion procedure (Haas Axis Lubrication Oil - Haas Service Manual).

WO.M.AI — AI Predictive Maintenance & Decision Support System Page 3 of 5

Gambar 22. Machine Condition Report, halaman 1: ringkasan informasi laporan dan kondisi rata-rata mesin.

Gambar 23. Machine Condition Report, halaman 2: prediksi risiko kegagalan, kontribusi fitur, dan diagnosis AI.

Gambar 24. Machine Condition Report, halaman 3: prosedur penanganan sesuai SOP berdasarkan manual servis.



AI Predictive Maintenance & Decision Support System

Affected Part / Component

80 mesh 0.625" diameter filter (P/N 58-1993A)

4. Estimated Machine Part Cost

This section provides a cost estimate for components that may be needed.

Part Name	Estimated Price Range	Link
30 50 60 80 Mesh Stainless Steel Prototype Round Mesh Filters for a Plant Grinder	IDR 13,587 - 13,587	View Product
4 Axis Controller Kit 4N Shaft 14mm Nema 34 78mm Stepper Motor Driver DM860H+ Power 350W 48V CNC Milling Kit	IDR 5,978,271 - 5,978,271	View Product
New Original 93-32-3551J 4SA Smart Driver Service Kit	IDR 15,036,257 - 15,036,257	View Product
Total Estimated Cost	**IDR 21,028,115 - 21,028,115**	

5. Machine Condition Log

This section contains the machine's condition history over the observed period.

No.	Timestamp	Air Temp	Process Temp	Rotational Speed	Tool Wear	Health Score	Failure Risk
1	25-08-2026 20:34 WIB	330.0 K	312.0 K	3128 RPM	240.0 min	44.85	55.1%

6. Summary

The Haas Milling Machine 2023 is currently experiencing a critical failure state with a low health score. A failure risk of 55.1% confirms that the system is operating outside of safe parameters. The root cause is the 80 mesh 0.625" diameter filter (Haas Liquid Grease - Haas Service Manual) which clogs and prevents consistent lubrication. High rpm settings exacerbate this mechanical stress and lead to the observed system breakdown.

WO.M.AI — AI Predictive Maintenance & Decision Support System Page 4 of 5

Gambar 25. Machine Condition Report, halaman 4: estimasi biaya komponen, log kondisi mesin, dan ringkasan laporan.



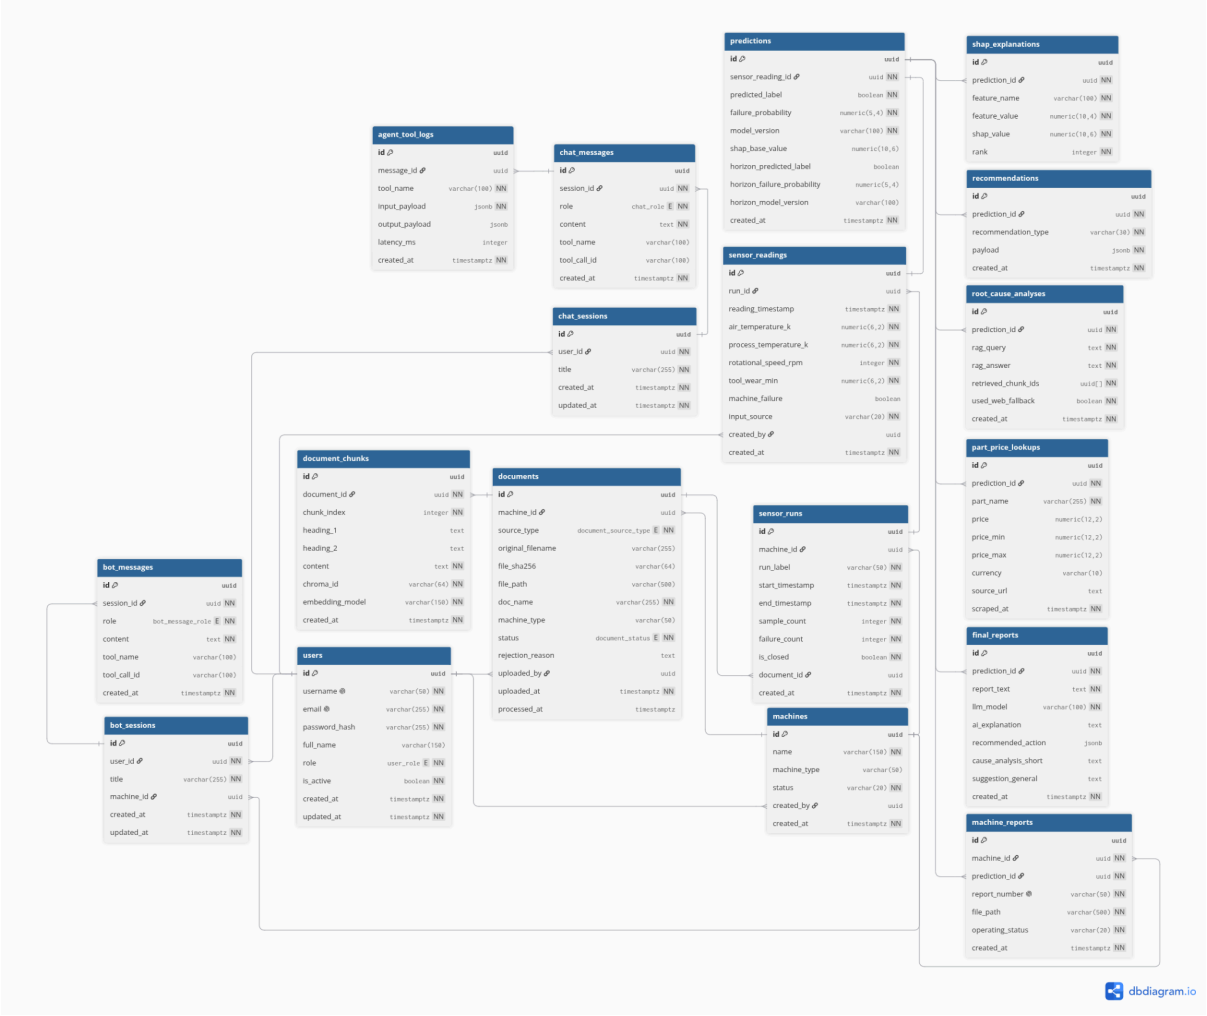
AI Predictive Maintenance & Decision Support System

Operators must immediately reduce the machine rpm to 1600.0 to lower thermal and mechanical loads. This action is a high-priority requirement to prevent further hardware damage. Maintenance personnel should replace the clogged filter assembly to restore proper lubrication flow. A follow-up inspection is necessary after the adjustment to verify that the system remains within safe operating limits.

WO.M.AI — AI Predictive Maintenance & Decision Support System Page 5 of 5

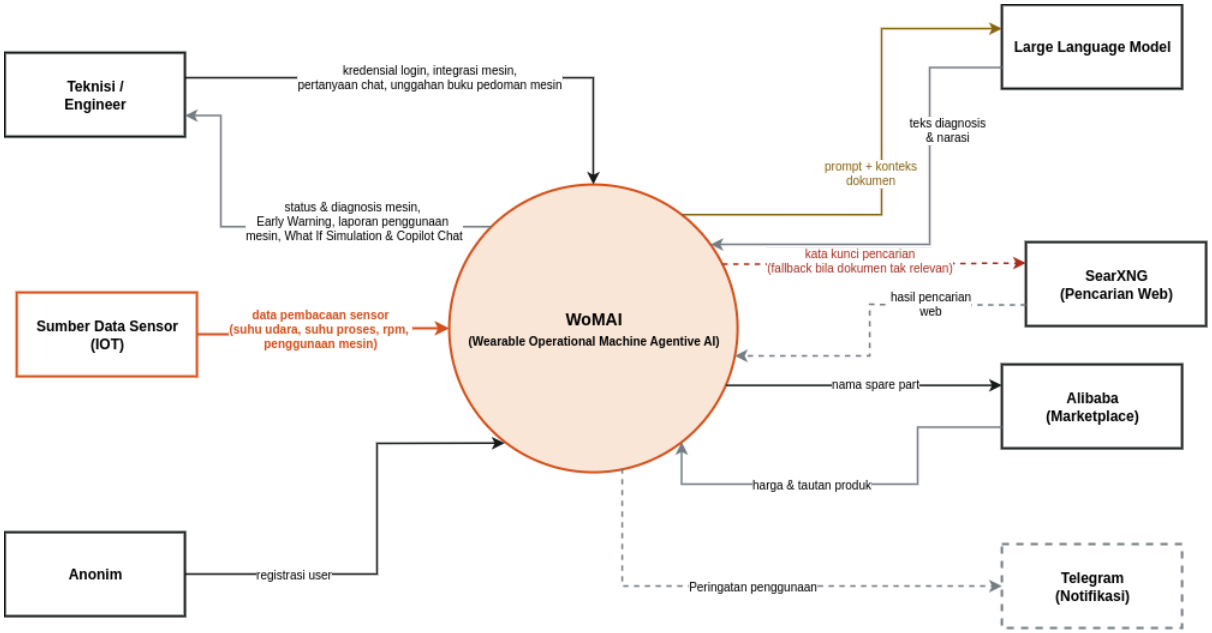
Gambar 26. Machine Condition Report, halaman 5: rekomendasi tindakan operator dan jadwal pemeriksaan lanjutan.

Lampiran 3. ERD System

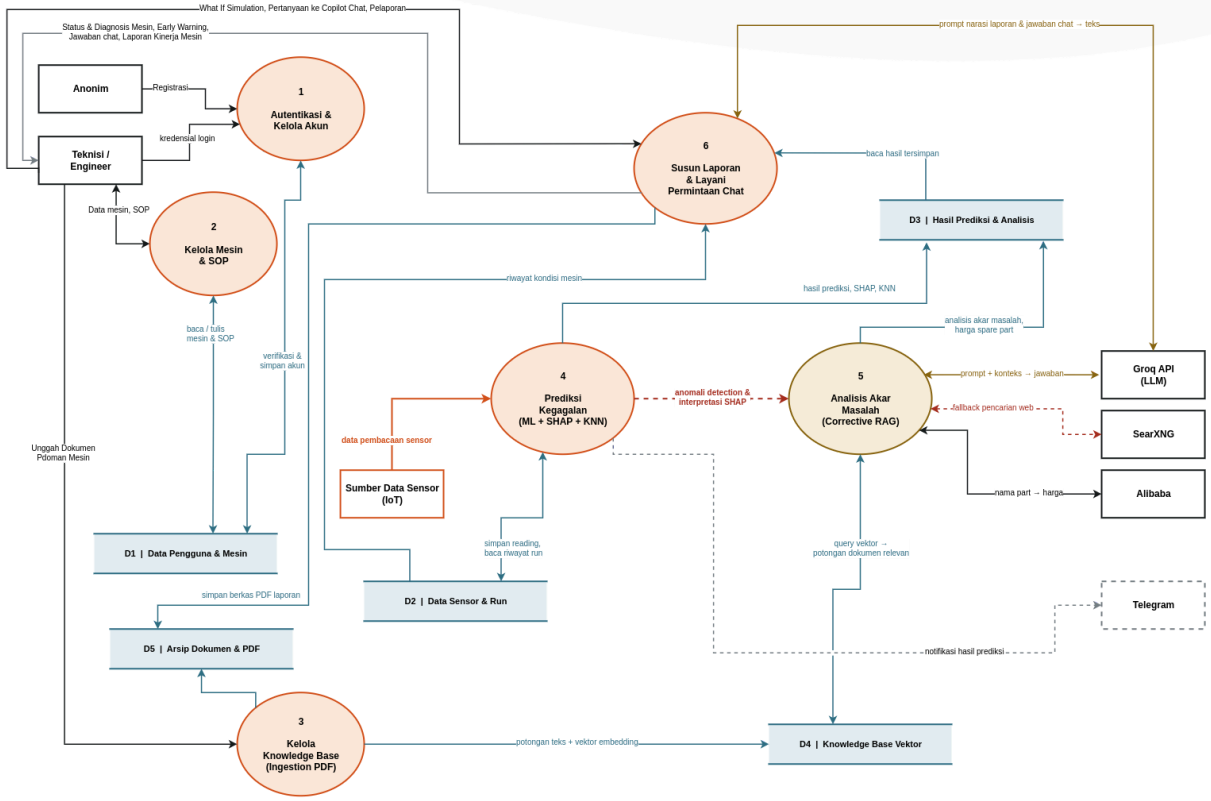


Gambar 27. Entity Relationship Diagram

Lampiran 4. DFD System



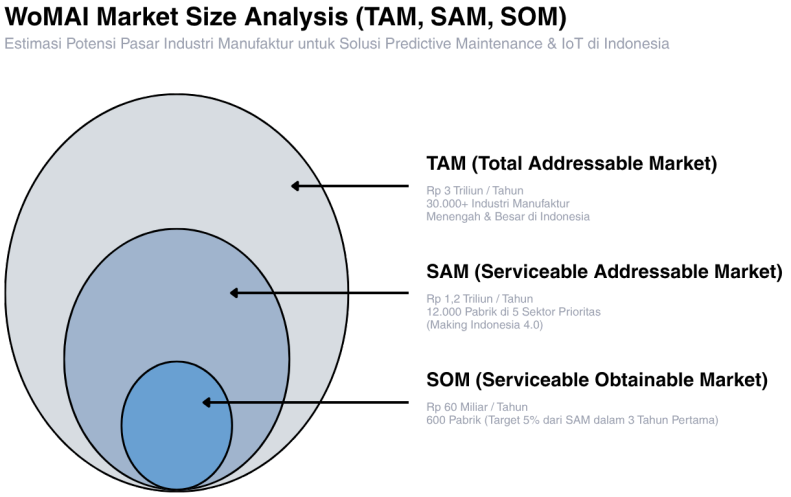
Gambar 28. DFD System Level 0



Gambar 29. DFD System Level 1

Lampiran 5. Bisnis Model Canvas

WoMAI (*Wearable Operational Machine Agentic AI*) adalah solusi inovatif B2B untuk pemeliharaan prediktif mesin industri di Indonesia. Dengan mengintegrasikan *hardware* sensor IoT (suhu udara, suhu mesin, dan sensor RPM inframerah) dengan *Agentic AI* (XGBoost, SHAP, *Corrective* RAG, dan PDF *Manual Ingestion*), WoMAI membantu pabrik mendeteksi kegagalan mesin sebelum terjadi, meminimalkan *unplanned downtime*, dan memberikan asisten teknis instan berbasis buku panduan resmi.



Gambar 30. *Market Size Analysis*

1. Analisis Ukuran Pasar (TAM, SAM, SOM)

   TAM (*Total Addressable Market*) - Rp3,0 Triliun / Tahun

   a. Total potensi pasar keseluruhan di Indonesia jika seluruh industri manufaktur skala menengah dan besar menerapkan teknologi pemeliharaan prediktif.
   b. Berdasarkan data Badan Pusat Statistik (BPS), terdapat sekitar 30.000 lebih unit industri manufaktur berskala menengah dan besar di Indonesia. Dengan asumsi alokasi anggaran pemeliharaan preventif dan korektif untuk mesin kritis rata-rata sebesar Rp100.000.000 per pabrik dalam satu tahun, total potensi pasar secara keseluruhan adalah Rp3.000.000.000.000 (Rp3,0 Triliun).

   SAM (*Serviceable Addressable Market*) - Rp1,2 Triliun / Tahun

   a. Bagian pasar TAM yang relevan dan dapat dilayani oleh solusi spesifik WoMAI, berfokus pada industri manufaktur yang memiliki ketergantungan mutlak pada mesin mekanis berputar berkecepatan tinggi.
   b. Menargetkan 12.000 pabrik di Indonesia yang bergerak dalam 5 sektor industri prioritas peta jalan Making Indonesia 4.0 (Makanan & Minuman, Otomotif, Tekstil, Kimia, dan Elektronik). Sektor-sektor ini sangat sensitif terhadap kegagalan mesin produksi berputar (seperti dinamo blower, pompa, kompresor, dan konveyor). Potensi pasar yang dapat dilayani ini bernilai Rp1.200.000.000.000 (Rp1,2 Triliun).

   SOM (*Serviceable Obtainable Market*) - Rp60 Miliar / Tahun

   a. Pangsa pasar yang realistis untuk diakuisisi oleh WoMAI dalam jangka waktu 3 tahun pertama operasional dengan berfokus pada klaster kawasan industri terpadu.
   b. Menargetkan akuisisi 5% dari SAM atau sekitar 600 pabrik yang terkonsentrasi di kawasan industri utama Jawa Timur (Gresik, Sidoarjo, Surabaya) dan Jawa Barat (Cikarang, Karawang, Cibitung). Dengan skema sewa/pembelian alat, WoMAI memproyeksikan pendapatan tahunan sebesar Rp60.000.000.000 (Rp60 Miliar) pada tahun ketiga.

2. *Market Opportunity* & Target Market (Peluang & Target Pasar)

   Metode pemeliharaan tradisional di Indonesia umumnya bersifat reaktif (*run-to-failure*) atau preventif terjadwal yang tidak mencerminkan kondisi riil komponen dalam mesin. Di sisi lain, solusi pemeliharaan prediktif impor dari korporasi global sangat mahal dan kaku. WoMAI menawarkan solusi alternatif berupa perangkat sensor eksternal yang murah dan fleksibel yang langsung terintegrasi dengan asisten AI pembuat laporan otomatis dan pencari solusi mandiri.

   Dengan target market persona *maintenance manager*, *plant/factory manager*, dan *Chief of Operations (COO)* yang bertanggung jawab atas efisiensi biaya perawatan dan produktivitas pabrik. Teknisi mesin (*maintenance engineers*) yang membutuhkan asisten pencari solusi kerusakan di lapangan tanpa harus membaca dokumen ratusan lembar secara manual.

Tabel 8. Asumsi dan Segmentasi Pasar

Kategori	Nilai Pasar	Asumsi / Segmentasi
TAM (Total Addressable Market)	Rp 3 Triliun / tahun	30.000 lebih industri manufaktur menengah besar di Indonesia dengan estimasi anggaran pemeliharaan Rp 100 Juta/pabrik/tahun.
SAM (Serviceable Addressable Market)	Rp 1,2 Triliun / tahun	12.000 pabrik (40% TAM) di 5 sektor prioritas inisiatif Making Indonesia 4.0 yang mengandalkan mesin berputar.
SOM (Serviceable Obtainable Market)	Rp 60 Miliar / tahun	Target realistis akuisisi 3 tahun pertama (5% SAM, atau -600 pabrik) berfokus pada kawasan industri utama Jawa Barat.

3. Potensi Dampak (*Potential Impact*)

Dampak finansial, mengurangi kerugian biaya akibat waktu henti produksi tak terencana (*unplanned downtime*) hingga 30% - 50%. Kerusakan mesin kritis pada lini produksi utama pabrik besar dapat menimbulkan kerugian finansial dari puluhan hingga ratusan juta rupiah per jam.

Dampak efisiensi operasional, memangkas waktu pencarian solusi teknis hingga 80%. Teknisi lapangan tidak perlu mencari lembar panduan secara manual, mereka cukup mengirimkan pertanyaan ke *AI Copilot* yang mengacu langsung pada dokumen PDF pedoman mesin asli yang sudah dimasukkan ke *database.*

Dampak Keselamatan Kerja (K3), deteksi dini temperatur abnormal atau fluktuasi RPM yang ekstrem mencegah terjadinya kecelakaan kerja berat akibat ledakan mesin, korsleting listrik, atau kerusakan mekanis fatal yang membahayakan nyawa pekerja di area pabrik.